



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده مهندسی کامپیوتر

گزارش نوشتاری درس روش پژوهش و ارائه

بررسی الگوریتم‌های هوش مصنوعی در پیش بینی
مصرف انرژی ساختمان‌ها

نگارش
فرشید نوشی

استاد راهنما
دکتر رضا صفا بخش

فروردین ۱۴۰۱

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

تقدیم به پدر بزرگوار و مادر مهربانم

آن دو فرشته‌ای که از خواسته‌هایشان گذشتند، سختی‌ها را به جان خریدند و خود را سپربلای مشکلات و ناملایمات
کردند تا من به جایگاهی که اکنون در آن ایستاده‌ام برسم.

سپاس‌گزاری

به مصداق «من لم يشكر المخلوق لم يشكر الخالق» بسی شایسته است از استاد فرهیخته و فرزانه جناب آقای دکتر رضا صفابخش که با کرامتی چون خورشید، سرزمین دل را روشنی بخشیدند و گلشن‌سرای علم و دانش را با راهنمایی‌های کارساز و سازنده بارور ساختند تقدیر و تشکر نمایم.

فریدنوشی
فروردین ۱۴۰۱

چکیده

پیش‌بینی مصرف انرژی برای ساختمان‌ها ارزش بسیار زیادی در تحقیقات بهره‌وری انرژی و پایداری دارد. مدل‌های پیش‌بینی دقیق انرژی، فواید متعددی در برنامه‌ریزی و بهینه‌سازی انرژی ساختمان‌ها و پردیس‌ها دارند. برای ساختمان‌های جدید، که در آن داده‌های ثبت شده گذشته در دسترس نیستند، از روش‌های شبیه‌سازی کامپیوتری برای تجزیه و تحلیل انرژی و پیش‌بینی سناریوهای آینده استفاده می‌شود. با این حال، برای ساختمان‌های موجود با داده‌های انرژی سری زمانی ثبت شده گذشته، تکنیک‌های آماری و یادگیری ماشین دقیق‌تر و سریع‌تر عمل کرده‌اند. این گزارش بررسی‌ای بر الگوریتم‌های هوش مصنوعی موجود برای پیش‌بینی مصرف انرژی سری زمانی انجام داده است. اگرچه تاکید بر یک تجزیه و تحلیل داده‌های سری زمانی منفرد است، اما بررسی فقط به آن محدود نمی‌شود زیرا داده‌های انرژی اغلب با سایر متغیرهای سری زمانی مانند آب و هوای بیرون و شرایط محیطی داخلی تجزیه و تحلیل می‌شوند. نه روش محبوب پیش‌بینی که بر اساس یادگیری ماشینی است، تجزیه و تحلیل می‌شوند. یک بررسی از "مدل ترکیبی"، که ترکیبی از دو یا چند تکنیک پیش‌بینی است نیز ارائه شده است. ترکیبات مختلف مدل ترکیبی موثرترین در پیش‌بینی انرژی سری زمانی برای ساختمان هستند.

واژه‌های کلیدی:

یادگیری ماشین، هوش مصنوعی، پیش‌بینی داده‌های سری زمانی، مصرف انرژی ساختمان‌ها

فهرست مطالب

صفحه

عنوان

۶	۲	روش‌های پیش‌بینی مصرف انرژی ساختمان‌ها
۷	۱-۲	روش آماری
۸	۲-۲	روش مهندسی
۹	۳-۲	روش هوش مصنوعی
۹	۱-۳-۲	شبکه‌های عصبی
۱۰	۲-۳-۲	ماشین بردار پشتیبان
۱۱	۴-۲	خلاصه
۱۲	۳	مروری بر الگوریتم‌های هوش مصنوعی مورد بررسی
۱۳	۱-۳	شبکه‌های عصبی مصنوعی
۱۴	۲-۳	ماشین بردار پشتیبان
۱۶	۳-۳	میانگین متحرک خودهمبسته یکپارچه
۱۷	۴-۳	سری زمانی فازی
۱۷	۵-۳	استدلال مبتنی بر مورد
۱۷	۶-۳	مدل‌های ترکیبی
۱۸	۷-۳	خلاصه
۱۹	۴	ارزیابی نتایج تجربی بر روی مجموعه‌های داده
۲۰	۱-۴	معیارهای ارزیابی
۲۰	۲-۴	مقایسه‌ی روش‌های مورد بررسی
۲۰	۳-۴	انتخاب بهینه‌ترین روش پیشنهادی
۲۰	۴-۴	خلاصه
۲۱	۵	نتیجه‌گیری و پیشنهادها
۲۲	۱-۵	نتیجه‌گیری
۲۲	۲-۵	پیشنهادها
۲۳		منابع و مراجع

شکل	فهرست اشکال	صفحه
۱-۱	اهمیت پیش‌بینی انرژی ساختمان‌ها برای بهینه‌سازی ساختمان‌ها	۵
۱-۳	پرسپترون	۱۳
۲-۳	شبکه‌ی عصبی مصنوعی	۱۴
۳-۳	ماشین بردار پشتیبان	۱۵
۴-۳	میانگین متحرک خودهمبسته یکپارچه	۱۶

صفحه	جدول	فهرست جداول
۱-۲	خلاصه‌ی کلی از متدهای پیش‌بینی و ویژگی‌های هریک	۱۱

فصل اول

مقدمه

آژانس بین‌المللی انرژی، بهره‌وری انرژی در ساختمان‌ها را به عنوان یکی از پنج اقدام برای تضمین کربن زدایی طولانی مدت بخش انرژی شناسایی کرده است [۱] در کنار مزایای زیست محیطی، بهره‌وری انرژی ساختمان دارای مزایای اقتصادی گسترده‌ای نیز می‌باشد. ساختمان‌هایی با سیستم‌های انرژی کارآمد و استراتژی‌های مدیریتی هزینه‌های عملیاتی بسیار کمتری دارند. اکنون بسیاری از کشورها اجرای قوانین و مقررات انرژی را برای انواع ساختمان‌ها تسریع کرده‌اند. این مقررات الزامات اساسی برای دستیابی به یک طراحی کارآمد انرژی برای ساختمان‌های جدید با هدف کاهش مصرف انرژی نهایی و انتشار CO₂ مرتبط را ترسیم می‌کند. علاوه بر این، بسیاری از نرم افزارهای کامپیوتری نیز برای طراحی بهینه انرژی ساختمان‌های جدید توسعه یافته و به طور گسترده پیاده سازی شده‌اند. در مورد تکنیک‌های موجود تجزیه و تحلیل انرژی ساختمان به کمک کامپیوتر و ابزارهای نرم افزاری در [۲، ۳] اطلاعات دقیقی موجود هستند. این مقررات و ابزارهای کامپیوتری مربوط به ساختمان‌های جدید است و در واقع بسیار موثر هستند. با این حال، هنگامی که ساختمان در حال فعالیت است، عوامل زیادی بر رفتار انرژی یک ساختمان حاکم هستند، مانند شرایط آب و هوایی، برنامه حضور ساکنین ساختمان، خواص حرارتی مصالح ساختمانی، فعل و انفعالات پیچیده سیستم‌های انرژی مانند گرمایش و تهویه‌ها و روشنایی و غیره. به دلیل این فعل و انفعالات پیچیده، محاسبه‌ی دقیق مصرف انرژی از طریق مدل شبیه سازی کامپیوتری بسیار دشوار است. به این دلایل، تکنیک‌های داده‌محور برای تجزیه و تحلیل مصرف انرژی ساختمان‌های موجود بسیار حیاتی است. این تکنیک‌ها بر داده‌های ثبت‌شده گذشته تکیه دارند و تلاش می‌کنند مصرف انرژی را بر اساس الگوهای مصرف انرژی قبلی مدل‌سازی کنند. سایر عوامل مؤثر بر مصرف انرژی را می‌توان برای بهبود دقت چنین مدل‌های سری زمانی استفاده کرد. این تکنیک‌ها که از داده‌های گذشته استفاده می‌کنند، اغلب تحت «یادگیری ماشین» قرار می‌گیرند و در دو دهه اخیر به طور فعال در مطالعات پیش‌بینی انرژی ساختمان به کار رفته‌اند

۱-۱ اهمیت بهینه سازی عملکرد ساختمان‌ها [۱]

برای دستیابی به سطح بهینه عملکرد انرژی در ساختمان‌ها، نصب سیستم‌های انرژی کارآمد باید با استراتژی‌های عملیاتی و مدیریتی مناسب دنبال شود. این امر مستلزم نظارت و مدیریت مداوم داده‌های انرژی سری زمانی همراه با سایر عوامل مؤثر بر عملکرد انرژی ساختمان‌ها است. در رابطه با نظارت مستمر و مدیریت مصرف انرژی در ساختمان‌های موجود، پیش‌بینی نقش بسزایی دارد. می‌تواند مجموعه‌ای از شرایط مرزی و اهداف را برای مدیران و مالکان تأسیسات ساختمانی فراهم کند که مصرف انرژی ساختمان به طور ایده‌آل باید در آن قرار گیرد (هدف‌های روزانه، هفتگی، ماهانه و سالانه). همانطور که مدل پیش‌بینی سری‌های زمانی از الگوهای مصرف انرژی قبلی یاد می‌گیرد، افزایش تدریجی مقادیر مصرف انرژی پیش‌بینی‌شده در یک دوره زمانی ممکن است مدیران تأسیسات را در مورد جنبه‌های تعمیر و نگهداری ساختمان و سیستم‌های انرژی آگاه کند. علاوه بر رویکرد پیش‌بینی سری‌های زمانی، سایر رویکردهای سری غیرزمانی را می‌توان برای اهداف بهینه‌سازی ساختمان اتخاذ کرد و همچنین می‌توان

آنها را با سایر مدل‌های شبیه‌سازی کامپیوتری برای استخراج اشغال و سایر عوامل عملیاتی ترکیب کرد. یانگ^۱ و همکاران در بهینه‌سازی انرژی مبتنی بر شبیه‌سازی برای یک ساختمان آزمایشی در اسپانیا، یک چارچوب بهینه‌سازی الگوریتم ژنتیک موازی مبتنی بر وب^۲ که از منابع محاسباتی توزیع‌شده استفاده می‌کند تا زمان محاسبه را کاهش دهد استفاده کردند. پتری^۳ و همکاران یک سیستم بهینه‌سازی مبتنی بر مدولار ارائه کردند که شبیه‌سازی انرژی و بهینه‌سازی را با استفاده از شبکه عصبی مصنوعی ترکیب می‌کند. این برنامه کاهش قابل توجه انرژی (کیلووات ساعت) را در یک سناریوی واقعی نشان داد. با این حال، این امر مستلزم تجهیز ساختمان به حسگرها و عملگرها برای نظارت، کنترل و بهینه‌سازی بود. این ممکن است در مورد اکثر زیرساخت‌های ساختمان موجود نباشد. چنین چالش‌هایی مورد بحث قرار می‌گیرند. با این حال، همچنین خاطرنشان می‌شود که پتانسیل صرفه جویی انرژی مرتبط در ساختمان‌ها به راه‌اندازی، ردیابی عملکرد و استراتژی‌های کنترل پیشرفته مربوط می‌شوند. این امر به عوامل بسیاری از جمله منابع مالی، حمایت از سیاست، آگاهی سبز، مواد سبز و فناوری و غیره وابسته است. زونگ^۴ و همکاران در مورد چالش‌های اجرای یک مدل اقتصادی استراتژی کنترل پیش‌بینی^۵ برای ساختمان‌های هوشمند بحث کردند. مشاهده شد که هنوز چالش‌هایی در کاربرد کنترل پیش‌بینی مدل از جمله سازش بین ساده‌سازی و پیچیدگی مدل‌سازی دینامیکی حرارتی ساختمان و تعادل بین سیستم‌های چند انرژی وجود دارد. هو و همکاران با درک چالش‌ها در ادغام داده‌های عملکرد ساختمان با سایر داده‌های مربوط به ساختمان. روش جدیدی را برای پیوند دادن داده‌های قطع شده سنتی برای ساخت منابع داده ارائه کرد تا ارزیابی عملکرد ساختمان را به صورت عمیق و روشن‌تر فراهم کند. پیش‌بینی سری‌های زمانی برای بهینه‌سازی عملکرد ساختمان ضروری است. هر تکنیک بهینه‌سازی به اطلاعاتی در مورد سناریوهای آینده یا یافتن بهترین راه‌حل‌ها در برابر یک معیار آزمایشی نیاز دارد. تکنیک‌های یادگیری ماشین در این زمینه مفید هستند و اغلب در حل این دو مشکل استفاده می‌شوند. با این حال، این بررسی بر جنبه‌های پیش‌بینی سری‌های زمانی بهینه‌سازی ساختمان تمرکز دارد تا اینکه به طور کلی به مسئله بهینه‌سازی نگاه کند. ادغام این دو باید در یک بررسی جداگانه مورد بررسی قرار گیرند.

۲-۱ اهداف بررسی [۱]

مطالعات بررسی اخیر در مورد پیش‌بینی انرژی، گزارش‌های دقیقی از مدل‌های پیش‌بینی موجود و طبقه‌بندی آنها ارائه می‌دهد. ژائو^۶ و ماگولس^۷ روش‌های موجود برای پیش‌بینی مصرف انرژی ساختمان

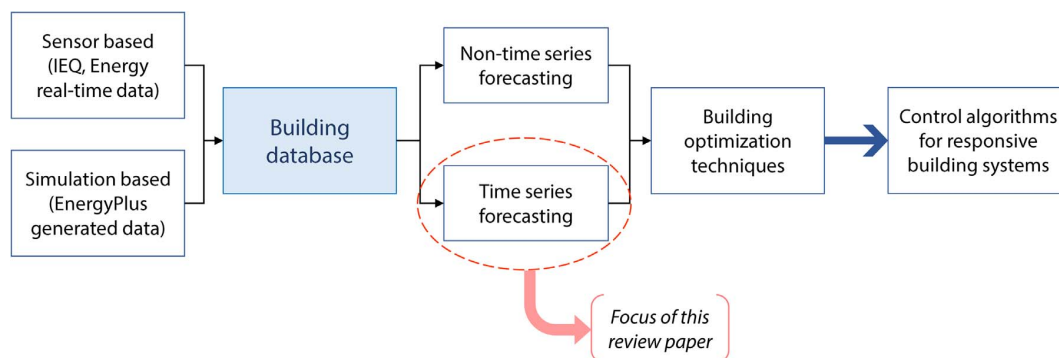
Yang^۱GA^۲Petri^۳Zong^۴EMPC^۵Zhao^۶Magoules^۷

را در پنج دسته بررسی و طبقه بندی کردند. هیپرت^۸ و همکاران مروری بر پیش بینی بار کوتاه مدت ارائه کرد. سوگانتی^۹ و ساموئل^{۱۰} مروری بر مدل های تقاضای انرژی برای پیش بینی تقاضا ارائه کردند. فومو^{۱۱} مروری بر برآورد انرژی ساختمان ارائه کرد و همچنین نحوه طبقه بندی مدل های برآورد را مورد مطالعه قرار داد. مارتینز-آلوارز^{۱۲} و همکاران یک نظرسنجی در مورد تکنیک های داده کاوی برای پیش بینی سری های زمانی الکتریسیته ارائه کرد. این نظرسنجی بر روی ویژگی های مدل ها و پیکربندی آنها متمرکز بود. رضا و خسروی مروری بر تکنیک های پیش بینی بار کوتاه مدت بر اساس تکنیک های هوش مصنوعی ارائه کردند. مطالعه اخیر توسط مت داوت^{۱۳} و همکاران مروری بر تحلیل پیش بینی مصرف انرژی الکتریکی ساختمان با استفاده از روش های مرسوم و هوش مصنوعی ارائه کرد. همه این بررسی ها اطلاعات حیاتی در مورد مدل های پیش بینی انرژی در مقیاس های مختلف ارائه می کنند و بر عملکرد برتر مدل های ترکیبی تأکید می کنند. یک مدل پیش بینی می تواند مبتنی بر داده های استاتیکی باشد که معمولاً یک متغیر وابسته را با مجموعه ای از متغیرهای مستقل منطبق می کند، یا می تواند از داده های سری زمانی منفرد یا موازی استفاده کند. این مطالعه بر تکنیک های پیش بینی با استفاده از داده های سری زمانی تأکید دارد که در عنوان این بررسی نیز منعکس شده است. اهمیت تجزیه و تحلیل سری های زمانی به دلیل افزایش آگاهی در جمع آوری و پایش داده ها در زمان واقعی است. مصرف انرژی سری زمانی را نیز می توان با داده های سری زمانی شرایط محیطی داخل ساختمان تنظیم کرد. با استقرار حسگرهای بیشتر در ساختمان ها و جمع آوری داده های سری زمانی بیشتر، یک چارچوب مناسب برای تجزیه و تحلیل و شناسایی قابلیت های پیش بینی مهم است. هدف این بررسی درک تکنیک های پیش بینی سری های زمانی موجود و ارائه مزایا و چالش های آنها است. ارزیابی دقیق مدل ترکیبی نیز به دلیل استفاده فزاینده در ادبیات ارائه شده است. از آنجایی که ترکیبات مدل هیبریدی بسیار زیاد است، اینها در بخش بعدی پس از بررسی انتقادی تکنیک های اصلی مانند شبکه ی عصبی مصنوعی^{۱۴} و میانگین متحرک خودهمبسته یکپارچه^{۱۵} مورد بررسی انتقادی قرار می گیرند. این مقاله مروری همچنین باید مبنایی برای مقایسه کیفی و کمی برای تمام ۹ تکنیک ذکر شده در اینجا فراهم کند. شایان ذکر است که مدل ترکیبی به عنوان یکی از تکنیک های موجود در بین ۹ تکنیک ارائه شده در نظر گرفته شده است. در مدل هیبریدی، در مجموع ۲۹ ترکیب وجود دارد که در این بررسی به آنها پرداخته شده است

Hippert^۸Suganthi^۹Samuel^{۱۰}Fumo^{۱۱}Martinez-Alvarez^{۱۲}Mat Daut^{۱۳}artificial neural network^{۱۴}ARIMA^{۱۵}

اهداف این مقاله مروری عبارتند از:

- ارائه بررسی‌ای جمعی و جامع از تکنیک‌های اصلی هوش مصنوعی پیش‌بینی سری‌های زمانی با توجه به مصرف انرژی ساختمان
- انجام یک تحلیل تطبیقی که شامل هر دو جنبه کیفی و کمی این تکنیک‌ها باشد
- تشریح ترکیبات مختلف مدل هیبریدی در حین ارزیابی عملکرد و تازگی آن‌ها



شکل ۱-۱ تمرکز این گزارش نوشتاری در حوزه بهینه‌سازی ساختمان [۱]

در فصل‌های بعدی نخست توضیحاتی در مورد پیش‌بینی مصرف انرژی ساختمان‌ها می‌دهیم و در مورد روش‌های تاریخی و قدیمی‌تر از الگوریتم‌های هوش مصنوعی صحبت خواهیم کرد که روش‌های مهندسی و آماری را شامل میشوند. در فصل ۳ الگوریتم‌های متنوع هوش مصنوعی برای پیش‌بینی سری داده‌های زمانی معرفی و به طور مفصل شرح داده میشوند و هر یک معادلات مورد نیازشان توضیح داده میشود. در فصل ۴ مجموعه‌های داده‌ی مختلف و معیارهای سنجش بین این الگوریتم‌ها معرفی میشوند و آزمایش‌های متنوع برای یافتن الگوریتم‌های مناسب را گزارش می‌دهیم و در نهایت در فصل ۵ با نتیجه‌گیری از مطالب گفته شده سعی در نتیجه‌گیری گزارش و ارائه‌ی پیشنهادات مناسب شده است.

فصل دوم

روش‌های پیش‌بینی مصرف انرژی ساختمان‌ها

پیش‌بینی داده‌های سری زمانی از زمان گذشته مورد توجه محققین و متخصصین بوده است. در نتیجه در گذر زمان روش‌های متنوعی برای این موضوع پیشنهاد شده‌اند. آمار و احتمالات از علوم بسیار قدیمی بشریت محسوب می‌شود یکی از روش‌های قدیمی برای پیش‌بینی داده‌های سری زمانی می‌باشد در کنار این روش، روش‌های مهندسی نیز در دهه‌های گذشته استفاده شده‌اند. در این فصل برای ارائه یک دید جامع و مناسب در مورد پیش‌بینی مصرف انرژی ساختمان‌ها در مورد هر دو روش گفته شده صحبت می‌کنیم و در نهایت در مورد روش‌های هوش مصنوعی توضیحاتی را ارائه می‌کنیم.

۱-۲ روش آماری

مدل‌های رگرسیون آماری صرفاً مصرف انرژی یا شاخص انرژی را با متغیرهای تأثیرگذار مرتبط می‌کنند. این مدل‌های تجربی از داده‌های عملکرد تاریخی ایجاد شده‌اند، به این معنی که قبل از آموزش مدل‌ها، باید داده‌های تاریخی کافی را جمع‌آوری کنیم. تحقیقات زیادی بر روی مدل‌های رگرسیون در مورد مسائل زیر انجام شده است. اولین مورد پیش‌بینی مصرف انرژی بر روی متغیرهای ساده شده مانند یک یا چند پارامتر آب و هوا است. مورد دوم پیش‌بینی برخی از شاخص انرژی مفید است. مورد سوم، تخمین پارامترهای مهم مصرف انرژی، مانند ضریب تلفات حرارتی کل، ظرفیت حرارتی کل و ضریب افزایش است که در تحلیل رفتار حرارتی ساختمان یا سیستم‌های سطح فرعی مفید هستند.

در برخی از مدل‌های مهندسی ساده‌شده، از رگرسیون برای ارتباط مصرف انرژی با متغیرهای آب و هوایی برای به دست آوردن امضای انرژی استفاده می‌شود [۴، ۵]. بائر^۱ و اسکارتزینی^۲ [۵] یک روش رگرسیون را برای انجام محاسبات گرمایش و سرمایش به طور همزمان با پرداختن به سودهای داخلی و همچنین خورشیدی پیشنهاد کردند. دار^۳ و همکاران [۶، ۷] بار گرمایش و سرمایش را در ساختمان‌های تجاری با دمای حباب خشک در فضای باز به عنوان تنها متغیر آب و هوا مدل‌سازی کرد. یک مدل سری فوریه مبتنی بر دما برای نشان دادن وابستگی غیرخطی بارهای گرمایش و سرمایش به زمان و دما پیشنهاد شد. اگر داده‌های رطوبت و خورشید نیز در دسترس باشد، آنها استفاده از مدل سری فوریه تعمیم‌یافته را پیشنهاد کردند زیرا ارتباط مهندسی بیشتر و توانایی پیش‌بینی بالاتری دارد. همچنین با در نظر گرفتن دمای حباب خشک به عنوان متغیر واحد برای توسعه مدل، لی^۴ و هو^۵ [۸] مدل‌های رگرسیونی را برای پیش‌بینی صرفه‌جویی در انرژی از پروژه‌های مقاوم‌سازی ساختمان‌های اداری در یک منطقه تابستانی گرم و زمستانی سرد ارزیابی کردند. آنها نشان دادند که یک مدل خطی تک متغیری برای مدل‌سازی مصرف انرژی در شرایط آب و هوایی گرم و سرد کافی و کاربردی است. ما^۶ و همکاران [۹] روش‌های رگرسیون خطی چندگانه و خود رگرسیون را برای پیش‌بینی مصرف انرژی ماهانه برای ساختمان‌های

Bauer^۱Scartezini^۲Dhar^۳Lei^۴Hu^۵Ma^۶

عمومی در مقیاس بزرگ ادغام کرد. در کار چو^۷ و همکاران [۱۰]، مدل رگرسیون در اندازه‌گیری‌های ۱ روزه، ۱ هفته‌ای و ۳ ماهه ایجاد شد که منجر به خطای پیش‌بینی در مصرف انرژی سالانه ۱۰۰٪، ۳۰٪، ۶٪ شد. این نتایج نشان می‌دهد که طول دوره اندازه‌گیری به شدت بر مدل‌های رگرسیون وابسته به دما تأثیر می‌گذارد.

در مورد پیش‌بینی شاخص انرژی، لام^۸ و همکاران [۱۱] از تجزیه و تحلیل اجزای اصلی^۹ برای ایجاد یک شاخص آب و هوایی زد^{۱۰} با توجه به تابش خورشیدی جهانی، دمای حباب خشک و مرطوب استفاده کرد. آنها دریافتند که زد^{۱۰} همان روندی را دارد که بار سرمایشی شبیه سازی شده، تهویه مطبوع و مصرف انرژی ساختمان را نشان می‌دهد. این روند از تحلیل همبستگی با تحلیل رگرسیون خطی به دست آمد. این مدل بر اساس داده‌های ۱۹۷۹ تا ۲۰۰۷ توسعه یافته است.

۲-۲ روش مهندسی

روش‌های مهندسی از اصول فیزیکی برای محاسبه دینامیک حرارتی و رفتار انرژی در کل سطح ساختمان یا برای اجزای سطح فرعی استفاده می‌کنند. آنها در طول پنجاه سال گذشته به اندازه کافی توسعه یافته‌اند. این روش‌ها را می‌توان به طور تقریبی به دو دسته روش جامع تفصیلی و روش ساده شده طبقه‌بندی کرد. روش‌های جامع از توابع فیزیکی بسیار دقیق یا دینامیک حرارتی برای محاسبه دقیق، گام به گام، مصرف انرژی برای همه اجزای ساختمان با اطلاعات ساختمان و محیط‌زیست، مانند شرایط اقلیمی خارجی، ساخت و ساز ساختمان، بهره‌برداری، برنامه نرخ بهره‌برداری استفاده می‌کنند. و تجهیزات گرمایش و تهویه هوا به عنوان ورودی. در این مقاله، ما بر دیدگاه جهانی مدل‌ها و برنامه‌ها تمرکز می‌کنیم، در حالی که جزئیات این فرآیندهای محاسباتی بسیار فراتر از هدف این بررسی است. خوانندگان ممکن است برای جزئیات محاسبه به [۱۲] مراجعه کنند. برای سیستم‌های گرمایش و تهویه هوا، به طور خاص، محاسبه دقیق انرژی در [۱۳] معرفی شده است. سازمان بین‌المللی استاندارد سازی، استاندارد برای محاسبه مصرف انرژی برای گرمایش و سرمایش فضا برای یک ساختمان و اجزای آن ایجاد کرده است. صدها ابزار نرم افزاری برای ارزیابی کارایی انرژی، انرژی‌های تجدیدپذیر و پایداری در ساختمان‌ها توسعه یافته‌اند. برخی از آنها به طور گسترده برای توسعه استانداردهای انرژی ساختمان و تجزیه و تحلیل مصرف انرژی و اقدامات حفاظتی ساختمان‌ها مورد استفاده قرار گرفته‌اند. این ابزارها در مقاله‌های [۳، ۱۴] بررسی شده‌اند. وزارت انرژی ایالات متحده فهرستی از تقریباً تمام ابزارهای شبیه سازی را که دائماً به روز می‌شود، نگهداری می‌کند.

اگرچه این ابزارهای شبیه سازی دقیق موثر و دقیق هستند، اما در عمل مشکلاتی وجود دارد. از آنجایی که این ابزارها مبتنی بر اصول فیزیکی هستند، برای رسیدن به یک شبیه‌سازی دقیق، به جزئیات ساختمان

Cho^۷
Lam^۸
PCA^۹
Z^{۱۰}

و پارامترهای محیطی به عنوان داده‌های ورودی نیاز دارند. از یک طرف، این پارامترها برای بسیاری از سازمان‌ها در دسترس نیستند، به عنوان مثال، اطلاعات مربوط به هر اتاق در یک ساختمان بزرگ همیشه دشوار است. این عدم وجود ورودی‌های دقیق منجر به شبیه‌سازی با دقت پایین می‌شود. از سوی دیگر، به کارگیری این ابزارها معمولاً نیازمند کار کارشناسی خسته‌کننده است که انجام آن را دشوار و هزینه‌بر می‌کند. به این دلایل برخی از محققان مدل‌های ساده‌تری را برای ارائه جایگزین‌هایی برای کاربردهای خاص پیشنهاد کرده‌اند.

الحمود^{۱۱} [۱۴] دو روش ساده شده را بررسی کرد. یکی روش درجه روز است که در آن تنها یک شاخص یعنی درجه روز تحلیل می‌شود. این روش حالت پایدار برای تخمین مصرف انرژی ساختمان‌های کوچک که در آن انرژی مبتنی بر پوشش غالب است، مناسب است. یکی دیگر از سطل، همچنین به عنوان روش فرکانس دما شناخته می‌شود، که می‌تواند برای مدل‌سازی ساختمان‌های بزرگ استفاده شود که در آن بارهای تولید شده داخلی غالب هستند یا بارها به طور خطی به اختلاف دمای بیرون و داخل خانه وابسته نیستند.

شرایط آب و هوایی عوامل مهمی برای تعیین میزان مصرف انرژی ساختمان هستند. اینها اشکال مختلفی مانند دما، رطوبت، تابش خورشیدی، سرعت باد دارند و در طول زمان تغییر می‌کنند. مطالعات خاصی برای ساده کردن شرایط آب و هوایی در محاسبات انرژی ساختمان انجام شده است.

۳-۲ روش هوش مصنوعی

روش‌های هوش مصنوعی در سال‌های اخیر رشد در زمینه‌ی پیش‌بینی مصرف انرژی ساختمان‌ها رشد بسیار زیادی داشته‌اند. به علت سهولت بهتر و دقت بالای این روش در سال‌های اخیر روش غالب در پیش‌بینی مصرف انرژی ساختمان‌ها این نوع روش‌ها بوده‌اند. در این بخش دو زیربخش مهم از روش‌های هوش مصنوعی مورد بررسی قرار گرفته‌اند.

۱-۳-۲ شبکه‌های عصبی^{۱۲}

شبکه‌های عصبی مصنوعی پرکاربردترین مدل‌های هوش مصنوعی در کاربرد پیش‌بینی انرژی ساختمان هستند. این نوع مدل در حل مسائل غیر خطی خوب است و یک رویکرد موثر برای این کاربرد پیچیده است. در بیست سال گذشته، محققان از شبکه‌های عصبی مصنوعی برای تجزیه و تحلیل انواع مختلف مصرف انرژی ساختمان در شرایط مختلف، مانند بار گرمایش/سرمایش، مصرف برق، عملکرد و بهینه‌سازی اجزای سطح زیرین، تخمین پارامترهای مصرف استفاده کرده‌اند. در این بخش، مطالعات قبلی را مرور می‌کنیم و با توجه به کاربردهایی که به آن پرداخته شده، آنها را در گروه‌هایی قرار می‌دهیم. علاوه بر این، بهینه‌سازی مدل، مانند پیش‌فرآیند داده‌های ورودی و مقایسه بین شبکه‌های عصبی مصنوعی و

^{۱۱} Al-Homoud

^{۱۲} Neural Networks

سایر مدل‌ها، در پایان برجسته شده است. در سال ۲۰۰۶، کالوگرو^{۱۳} [۱۵] مروری کوتاه بر شبکه‌های عصبی مصنوعی در کاربردهای انرژی در ساختمان‌ها، از جمله سیستم‌های گرمایش آب خورشیدی، تابش خورشیدی، سرعت باد، توزیع جریان هوا در داخل اتاق، پیش‌بینی مصرف انرژی، دمای هوای داخل ساختمان و سیستم گرمایش و تهویه هوا انجام داد. کالوگرو^{۱۸} و همکاران [۱۶] از شبکه‌های عصبی پس‌انتشار^{۱۴} برای پیش‌بینی بار گرمایش مورد نیاز ساختمان‌ها استفاده کرد. این مدل بر روی داده‌های مصرف ۲۲۵ ساختمان آموزش داده شد که تا حد زیادی از فضاهای کوچک تا اتاق‌های بزرگ متفاوت است. اولوفسون و همکاران [۱۷] تقاضای گرمایش سالانه تعدادی از ساختمان‌های کوچک خانواده‌ای در شمال سوئد را پیش‌بینی کرد. بعداً، اولوفسون^{۱۵} و اندرسون^{۱۶} [۱۸] یک شبکه عصبی ایجاد کردند که تقاضای انرژی بلندمدت (تقاضای گرمایش سالانه) را بر اساس داده‌های اندازه‌گیری شده کوتاه‌مدت (معمولاً ۲ تا ۵ هفته) با نرخ پیش‌بینی بالا برای ساختمان‌های تک خانواده پیش‌بینی می‌کند.

۲-۳-۲ ماشین بردار پشتیبان^{۱۷}

ماشین‌های بردار پشتیبان به طور فزاینده‌ای در تحقیقات و صنعت مورد استفاده قرار می‌گیرند. آنها مدل‌های بسیار موثری در حل مسائل غیر خطی حتی با مقادیر کم داده‌های آموزشی هستند. مطالعات بسیاری از این مدل‌ها در مورد تجزیه و تحلیل انرژی ساختمان در پنج سال گذشته انجام شده است. دونگ^{۱۸} و همکاران [۱۹] برای اولین بار از ماشین بردار پشتیبان برای پیش‌بینی مصرف برق ماهانه چهار ساختمان در منطقه گرمسیری استفاده کرد. داده‌های سه ساله آموزش داده شد و مدل مشتق شده برای پیش‌بینی سودمندی مالک در آن سال بر روی داده‌های یک ساله اعمال شد. نتایج نشان دهنده عملکرد خوب ماشین‌های بردار پشتیبان در این مشکل بود.

لای^{۱۹} و همکاران [۲۰] این مدل را بر مصرف برق یکساله یک ساختمان اعمال کرد. متغیرها شامل تغییرات آب و هوایی است. در آزمایشات آنها، این مدل از عملکرد یک سال استخراج شد و سپس بر روی رفتار سه ماهه آزمایش شد. آنها همچنین مدل را بر روی هر مجموعه داده روزانه آزمایش کردند تا پایداری این رویکرد را در دوره‌های کوتاه تأیید کنند. علاوه بر این، آنها اغتشاش را به صورت دستی به بخش خاصی از عملکرد تاریخی اضافه کردند و از این مدل برای تشخیص اغتشاش با بررسی تغییر وزن‌های کمک‌کننده استفاده کردند.

لیانگ^{۲۰} و دو^{۲۱} [۲۱] یک روش تشخیص عیب مقرون به صرفه را برای سیستم‌های گرمایش و تهویه

Kalogirou^{۱۳}

back propagation neural networks^{۱۴}

Olofsson^{۱۵}

Anderson^{۱۶}

Support Vector Machine(SVM)^{۱۷}

Dong^{۱۸}

Lai^{۱۹}

Liang^{۲۰}

Du^{۲۱}

متد	پیچیدگی مدل	سادگی استفاده	سرعت اجرا	نیازهای ورودی	دقت
مهندسی دقیق	نسبتاً بالا	غیر ساده	کم	با جزئیات	نسبتاً بالا
مهندسی ساده سازی شده	بالا	ساده	بالا	ساده سازی شده	بالا
آماري	معمولی	ساده	نسبتاً بالا	داده‌های تاریخی	معمولی
شبکه‌های عصبی مصنوعی	بالا	غیر ساده	بالا	داده‌های تاریخی	بالا
ماشین بردار پشتیبان	نسبتاً بالا	غیر ساده	کم	داده‌های تاریخی	نسبتاً بالا

جدول ۱-۲ خلاصه‌ی کلی از متدهای پیش‌بینی و ویژگی‌های هریک

هوا با ترکیب مدل فیزیکی و یک ماشین بردار پشتیبان ارائه کردند. با استفاده از طبقه‌بندی کننده چهار لایه ماشین بردار پشتیبان، می‌توان وضعیت عادی و سه خطای احتمالی را با تعداد کمی از نمونه‌های آموزشی به سرعت و با دقت تشخیص داد.

۴-۲ خلاصه

با توجه به توصیف و تحلیل فوق، بدیهی است که برای ارزیابی سیستم انرژی ساختمان، از سطح زیرسیستم تا سطح ساختمان و حتی سطح منطقه ای یا ملی، محاسبات زیادی مورد نیاز است. هر مدل در موارد خاصی از کاربردها مزایای خاص خود را دارد. مدل مهندسی تغییرات زیادی را نشان می‌دهد. ملاحظات زیادی می‌تواند در توسعه این مدل دخیل باشد. می‌تواند یک مدل بسیار پیچیده و جامع باشد که برای محاسبات دقیق قابل استفاده است. در مقابل، با اتخاذ برخی استراتژی‌های ساده‌کننده، می‌توان آن را به یک مدل سبک تبدیل کرد و با حفظ دقت، توسعه آن آسان است. یک اشکال رایج پذیرفته شده این مدل مهندسی دقیق این است که به دلیل پیچیدگی زیاد و کمبود اطلاعات ورودی، اجرای آن در عمل دشوار است. توسعه مدل آماری نسبتاً آسان است اما اشکالات آن نیز مشهود است که عبارتند از عدم دقت و عدم انعطاف پذیری. شبکه‌های عصبی مصنوعی و ماشین‌های بردار پشتیبان در حل مسائل غیر خطی خوب هستند و آنها را برای پیش‌بینی انرژی ساختمان کاربردی می‌کند. تا زمانی که انتخاب مدل و تنظیم پارامترها به خوبی انجام شود، آنها می‌توانند پیش‌بینی بسیار دقیقی ارائه دهند. ماشین‌های بردار پشتیبان حتی در بسیاری از موارد عملکرد بهتری نسبت به شبکه‌های عصبی مصنوعی نشان می‌دهند [۲۲]. معایب این دو نوع مدل این است که به داده‌های عملکرد تاریخی کافی نیاز دارند و بسیار پیچیده هستند. تجزیه و تحلیل مقایسه‌ای این مدل‌های رایج در جدول ۱ خلاصه شده است.


فصل سوم

مروری بر الگوریتم‌های هوش مصنوعی مورد بررسی

در این بخش می‌خواهیم با انجام یک مرور بر روی الگوریتم‌های مختلف هوش مصنوعی که برای پیش‌بینی کردن داده‌های سری زمانی معمولاً مورد استفاده قرار می‌گیرند آشنایی کلی با هریک از آن‌ها به‌دست بیاوریم. بخش بزرگی از مسئولیت پیش‌بینی داده‌های سری زمانی برعهده ی یادگیری ماشین که خود یک بخش بزرگ از هوش مصنوعی می‌باشد هست. از جمله الگوریتم‌های مهم در این بخش شبکه‌های عصبی مصنوعی، ماشین‌های بردار پشتیبان، میانگین متحرک خودهمبسته یکپارچه، سری زمانی فازی و استدلال مبتنی بر مورد هستند. در نهایت در پایان این بخش خلاصه ای از آنچه تا به حال در مورد این الگوریتم‌ها گفته شد خواهد آمد.

۱-۳ شبکه‌های عصبی مصنوعی

شبکه‌های عصبی مصنوعی یک دسته از مدل‌های غیرخطی و غیرپارامتری هستند که برای تقریب عملکردهای غیرخطی و چندمتغیره عمومی آموزش داده میشوند. این نوع شبکه‌ها سیستم‌های کاملاً موازی هستند که از عناصر پردازشی به هم پیوسته به نام پرسپترون تشکیل شده‌اند. (پرسپترون یک شبیه سازی پایه ای از نورون مغز انسان هست) یکی از مزایای اصلی شبکه‌های عصبی در مقایسه با مدل‌های دیگر عدم نیاز آن‌ها به داشتن فرضیات خاص می‌باشد. در شکل ۱-۳ از یک پرسپترون آمده است که نحوه ی کارکرد آن به طور کلی با تابع ریاضی زیر مدل میشود.




شکل ۱-۳ پرسپترون

$$output = f(\sum_{i=1}^n (x_i * w_i)) \quad (1-3)$$

در معادله ی ۱-۳ ورودی‌های پرسپترون برابر با x هستند و به تعداد ورودی‌های پرسپترون وزن‌های w_i در ۱-۳ ورودی‌ها ضرب شده و حاصل جمع این عبارت به یک تابع فعال‌سازی در پرسپترون داده میشود. که در معادله ی بالا این تابع فعال‌سازی $f(x)$ فرض شده است.

شبکه‌ی عصبی مجموعه‌ای چندلایه از این پرسپترون‌ها می‌باشد که پرسپترون‌های هرلایه به تمام پرسپترون‌های لایه‌ی بعدی وصل شده و لایه‌ی ورودی ورودی‌های مسئله‌ی ما هستند و خروجی شبکه‌ی عصبی نیز خروجی خواسته شده‌ی ما هست. در شکل ۲-۳ یک شبکه‌ی عصبی نمونه آورده شده است.



شکل ۲-۳ شبکه‌ی عصبی مصنوعی

۲-۳ ماشین بردار پشتیبان

بر اساس اصل به حداقل رساندن خطر ساختاری از نظریه یادگیری آماری، ماشین بردار پشتیبان در ابتدا برای حل مسئله شناسایی الگوی دو طبقه معرفی شد. ایده اصلی ساخت یک جداکننده است که در حالی که کوچکترین حاشیه را به حداکثر می‌رساند (به عنوان مثال برای دستیابی به بزرگترین حاشیه از دو کلاس داده)، موارد مثبت و منفی را از هم جدا می‌کند. ماشین بردار پشتیبان دو مزیت مهم دارد:

۱. انتخاب ویژگی اغلب مورد نیاز نیست، زیرا نسبت به بیشبرازش نسبتاً قوی است و میتواند تا ابعاد بالا را مقیاسبندی کند.


۲. هیچ تلاشی در تنظیم پارامتر لازم نیست، زیرا نشان داده شده است که گزینه‌ی "پیش فرض" از لحاظ نظری، برای تنظیم بیشترین اثربخشی ارائه میشود

از ماشین بردار پشتیبان برای حل دو نوع مسئله‌ی طبقه بندی و رگرسیون استفاده میشود. این روش در سال‌های گذشته عملکرد مناسبی در این دو مسئله داشته است. این روش از جمله روش‌های نسبتاً جدیدی است که در سال‌های اخیر کارایی خوبی نسبت به روش‌های قدیمی‌تر برای طبقه‌بندی نشان داده‌است. مبنای کاری دسته‌بندی کننده ماشین بردار پشتیبان دسته‌بندی خطی داده‌ها است و در تقسیم خطی داده‌ها سعی می‌کنیم خطی را انتخاب کنیم که حاشیه اطمینان بیشتری داشته باشد. قبل

از تقسیم خطی برای اینکه ماشین بتواند داده‌های با پیچیدگی بالا را دسته‌بندی کند داده‌ها را به وسیله تابع ϕ به فضای با ابعاد خیلی بالاتر می‌بریم. برای اینکه بتوانیم مسئله ابعاد خیلی بالا را با استفاده از این روش‌ها حل کنیم از قضیه دوگانگی لاگرانژ برای تبدیل مسئله مینیمم‌سازی مورد نظر به فرم دوگانگی آن که در آن به جای تابع پیچیده ϕ که ما را به فضایی با ابعاد بالا می‌برد، تابع ساده‌تری به نام تابع هسته که ضرب برداری تابع ϕ است ظاهر می‌شود استفاده می‌کنیم. از توابع هسته مختلفی از جمله هسته‌های نمایی، چندجمله‌ای و سیگموئید می‌توان استفاده نمود.

به طور خلاصه برای ماشین بردار پشتیبان باید ماتریس الگو را آماده می‌کنیم. تابع کرنلی را برای استفاده انتخاب می‌کنیم. پارامتر تابع کرنل و مقدار C را انتخاب می‌کنیم. برای محاسبه مقادیر a_i الگوریتم آموزشی را با استفاده از حل‌کننده‌های QP اجرا می‌کنیم. داده‌های جدید با استفاده از مقادیر a_i و بردارهای پشتیبان می‌توانند دسته‌بندی شوند.

هدف ماشین بردار پشتیبان به مانند شکل ۳-۳ پیدا کردن دو ابرصفحه در حاشیه‌ی دو دسته از داده‌ها است که از یکدیگر بیشترین فاصله ی ممکن را داشته باشند.



شکل ۳-۳ ماشین بردار پشتیبان

۳-۳ میانگین متحرک خودهمبسته یکپارچه^۱

مدل‌های میانگین متحرک خودهمبسته یکپارچه^۱ اساسی‌ترین و عمومی‌ترین شکل تکنیک‌های پیش‌بینی سری‌های زمانی هستند. اینها بر اساس ایده تبدیل سری‌های زمانی به ثابت بودن توسط فرآیند تفاضل هستند. اگر خصوصیات آماری آن در طول زمان ثابت باشند، می‌توان سری زمانی را ثابت فرض کرد. بنابراین، معادله میانگین متحرک خودهمبسته برای یک سری زمانی، یک معادله خطی است که ورودی آن شامل تأخیرهای متغیر وابسته به همراه تأخیرهای خطای پیش‌بینی است. این مدل میتواند به صورت ۳-۴ توضیح داده بشود.

$$\text{Output 'y'} = \text{constant} + \text{weighted sum of one or more past values of 'y'} \\ + \text{weighted sum of one or more past values of error 'e'}$$

شکل ۳-۴ میانگین متحرک خودهمبسته یکپارچه

تأخیرهای عبارت خطا را نمی‌توان به عنوان متغیر مستقل در نظر گرفت زیرا آنها توابع خطی ضرایب نیستند. از این رو، ضرایب مدل‌های میانگین متحرک خودهمبسته یکپارچه با خطاهای تأخیری باید با تکنیک‌های دیگری مانند بهینه‌سازی غیرخطی محاسبه شوند. اصطلاحات تأخیر سری‌های زمانی ثابت به عنوان «خودرگرسیون» نامیده می‌شوند، در حالی که تأخیرهای عبارات خطای پیش‌بینی شده به عنوان «میانگین متحرک» نامیده می‌شوند. سری زمانی که برای ثابت کردن آن نیاز به تفکیک دارد، نسخه «یکپارچه» یک سری ثابت است. این مدل‌ها به صورت $ARIMA(p, d, q)$ نشان داده می‌شوند، جایی که p نشان‌دهنده ترتیب قسمت اتورگرسیون^۲ d درجه اولین تفاوت درگیر و q نشان‌دهنده ترتیب قسمت میانگین متحرک است.

بخش اتورگرسیون مدل با مرتبه p مانند معادله ۳-۲ نشان داده می‌شود.

$$Y_t = c + \Phi_1 Y_{t-1} + \Phi_2 Y_{t-2} + \dots + \Phi_p Y_{t-p} + e_t \quad (۳-۲)$$

همچنین مدل میانگین متحرک q به صورت معادله ۳-۳ تعریف میشود:

$$Y_t = c + \Theta_1 e_{t-1} + \Theta_2 e_{t-2} + \dots + \Theta_p e_{t-p} + e_t \quad (۳-۳)$$

جایی که Y خروجی یک سری زمانی مانند داده‌های مصرف برق و e_t سری خطا است. این مدل‌ها از یک روش رایج پیروی می‌کنند که می‌توان آن را با جزئیات در کار باکس و جنکینز یافت [۲۳]

^۱ ARIMA
^۲ autoregressive

۴-۳ سری زمانی فازی

سری های زمانی فازی مشاهدات سری زمانی با مقادیر زبانی هستند تا مقادیر عددی معمولی یا واضح مشاهدات. بنابراین، قوانین مرسوم تحلیل سری های زمانی را نمی توان برای مطالعه این موارد به کار برد. سانگ^۳ و چیسوم^۴ [۲۴] این مفهوم را معرفی کردند و چندین تعریف رسمی برای سری های زمانی فازی ارائه کردند. مطالعات بعدی بر تقسیم بندی جهان گفتمان و به دنبال آن ایجاد روابط فازی متمرکز شد. سپس مقادیر پیش بینی شده و برای به دست آوردن خروجی عددی غیرفازی می شوند. لازم به ذکر است که انتخاب مناسب طول هر بازه فازی می تواند دقت پیش بینی را بسیار بهبود بخشد. برای مطالعات پیش‌بینی انرژی ساختمان، چالش در استخراج وزن‌های روابط منطق فازی، توابع عضویت و قوانین نهفته است.

۵-۳ استدلال مبتنی بر مورد^۵

استدلال مبتنی بر مورد^۵ مبتنی بر یادآوری اطلاعات از یک پرونده قبلی برای حل یک پرونده جدید است. با ایده استخراج قواعد از مشاهدات که می تواند در یک مجموعه عمومی اعمال شود، مخالف است. بلکه این فرآیند متکی بر موارد مشابهی است که در گذشته به آن پرداخته شده است و نه چندان متدولوژی حل آنها. منبع دانش اولیه در استدلال مبتنی بر مورد^۵ حافظه ای از موارد ذخیره شده است که قسمت های قبلی خاص را ضبط می کند [۲۵]. فرمول اولیه این مفهوم برگرفته از مطالعه نقش یادآوری در استدلال انسان است [۲۶]. جزئیات بیشتر در مورد مبانی نظری در استدلال مبتنی بر مورد را می توان در [۲۷] یافت. استدلال مبتنی بر مورد در کاربرد خود در پیش‌بینی مصرف انرژی ساختمان، مواردی را در نظر می‌گیرد که دارای انواع مشابهی از متغیرهای ورودی هستند و سعی می‌کند بر اساس سناریوهای مشابه قبلی مدل‌سازی کند.

۶-۳ مدل‌های ترکیبی^۶

مدل های ترکیبی ترکیبی از دو یا چند تکنیک یادگیری ماشینی هستند. این مدل‌ها قوی‌تر هستند، زیرا اغلب مزایای تکنیک‌های فردی درگیر را تحسین می‌کنند و دقت پیش‌بینی را بهبود می‌بخشند. متدهای بسیار متنوعی برای مدل‌های ترکیبی پیاده‌سازی و تست شده‌اند. از میان انبوهی از این مدل‌ها می‌توانیم به چند مورد زیر اشاره بکنیم:

- شبکه‌های عصبی مصنوعی و الگوریتم‌های تکاملی [۲۸]

^۳Song

^۴Chissom

^۵Case-based reasoning

^۶□□□□□□ □□□□□□

- ماشین بردار پشتیبان و میانگین متحرک خودهمبسته یکپارچه [۲۹]
- شبکه عصبی فازی در حال تکامل وزنی [۳۰]
- شبکه‌ی عصبی مصنوعی و میانگین متحرک خودهمبسته یکپارچه [۳۱]
- ...

لازم به ذکر است که توضیحات مربوط به مدل‌های ترکیبی و معادلات مربوط به هریک در بخش مربوط به کامل کردن متون ارائه خواهند شد.

۷-۳ خلاصه

با توجه به توضیحات داده شده ی بالا هر یک از این الگوریتم‌ها مزایا و معایب خودشان را در کار عملی پیش‌بینی داده‌های سری زمانی نشان خواهند داد. در مسیر پیش‌بینی داده‌های زمانی مصرف انرژی ساختمان‌ها از الگوریتم‌های مختلفی همچون ماشین بردار پشتیبان، شبکه‌های عصبی مصنوعی، میانگین متحرک خودهمبسته یکپارچه، سری زمانی فازی، استدلال مبتنی بر مورد و مدل‌های ترکیبی استفاده شده است. به طور کلی مدل‌های متنوع دیگری نیز در این مسئله وجود دارند که قادر به ارائه‌ی نتایج دقیق به متخصصین هستند. نکته‌ی بسیار مهم در این الگوریتم‌ها این است که اغلب آن‌ها به تنهایی و بدون داشتن مجموعه‌ی داده‌های آموزشی که کیفیت مناسبی را دارند کارایی چندانی مناسبی نخواهند داشت. لازم به ذکر است که الگوریتم‌های هوش مصنوعی نیازمند منابع محاسباتی گسترده‌ای هستند که خود این امر یک محدودیت برای آن‌ها به حساب می‌آید. در صورتی که هریک از این موارد برای این الگوریتم‌ها رعایت نشوند یعنی داده‌های زیاد و با کیفیت و همچنین ارائه‌ی سیستم‌های قدرتمند برای انجام محاسبات به نتیجه‌ی مطلوب و دلخواه نخواهیم رسید.

فصل چهارم

ارزیابی نتایج تجربی بر روی مجموعه‌های داده

پس از معرفی الگوریتم‌های متنوع و شرح مسئله نوبت به بررسی و ارزیابی آن‌ها بر روی مجموعه‌های داده متنوع می‌شود. در این فصل ابتدا معیارهای ارزیابی معرفی شده‌اند و سپس نتایج الگوریتم‌های مختلف معرفی شده برای پیش‌بینی داده‌های سری‌های زمانی مصرف انرژی ساختمان‌ها معرفی و مورد بحث قرار گرفته‌اند. و در نهایت بهینه‌ترین روش‌ها در صورت ممکن معرفی شدند.

۱-۴ معیارهای ارزیابی

میانگین درصد مطلق خطا^۱، همچنین به عنوان میانگین درصد انحراف مطلق^۲ شناخته می‌شود، معیاری برای دقت پیش‌بینی یک روش پیش‌بینی در آمار است. معمولاً دقت را به عنوان نسبتی که با فرمول ۱-۴ تعریف می‌شود بیان می‌کند:

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right| \quad (1-4)$$

که در آن A_t مقدار واقعی و F_t ارزش پیش‌بینی شده است. تفاوت آن‌ها بر ارزش واقعی A_t تقسیم می‌شود. مقدار مطلق در این نسبت برای هر نقطه پیش‌بینی شده در زمان جمع می‌شود و بر تعداد نقاط برازش n تقسیم می‌شود.

میانگین درصد مطلق خطا^۱ معمولاً به عنوان یک تابع ضرر^۳ برای مسائل رگرسیونی و در ارزیابی مدل استفاده می‌شود، زیرا تفسیر بسیار شهودی آن بر حسب خطای نسبی است.

۲-۴ مقایسه‌ی روش‌های مورد بررسی

۳-۴ انتخاب بهینه‌ترین روش پیشنهادی

۴-۴ خلاصه

^۱ mean absolute percentage error (MAPE)

^۲ mean absolute percentage deviation (MAPD)

^۳ Loss function

فصل پنجم

نتیجه‌گیری و پیشنهادها

در پایان گزارش‌های علمی و فنی لازم است که جمع‌بندی یا نتیجه‌گیری نهایی ارائه شود. در این موارد می‌توان آخرین فصل پایان نامه که پیش از مراجع قرار می‌گیرد را به این امر اختصاص داد.

۱-۵ نتیجه‌گیری

در این بخش پیشنهاداتی که محقق جهت ادامه تحقیقات دارد ارائه می‌گردد. دقت شود که پیشنهادات باید از تحقیق انجام شده و نتایج آن حاصل شده باشد و از ذکر جملات کلی باید پرهیز کرد.

۲-۵ پیشنهادها

منابع و مراجع

- [1] Deb, Chirag, Zhang, Fan, Yang, Junjing, Lee, Siew Eang, and Shah, Kwok Wei. A review on time series forecasting techniques for building energy consumption. *Renewable and Sustainable Energy Reviews*, 74:902–924, 2017.
- [2] Al-Homoud, Mohammad Saad. Computer-aided building energy analysis techniques. *Building and Environment*, 36(4):421–433, 2001.
- [3] Crawley, Drury B., Hand, Jon W., Kummert, Michaël, and Griffith, Brent T. Contrasting the capabilities of building energy performance simulation programs. *Building and Environment*, 43(4):661–673, 2008. Part Special: Building Performance Simulation.
- [4] Pfafferott, Jens, Herkel, Sebastian, and Wapler, Jeannette. Thermal building behaviour in summer: long-term data evaluation using simplified models. *Energy and Buildings*, 37(8):844–852, 2005.
- [5] Bauer, M and Scartezzini, J-L. A simplified correlation method accounting for heating and cooling loads in energy-efficient buildings. *Energy and Buildings*, 27(2):147–154, 1998.
- [6] Dhar, A, Reddy, TA, and Claridge, DE. Modeling hourly energy use in commercial buildings with fourier series functional forms. 1998.
- [7] Dhar, A, Reddy, TA, and Claridge, DE. A fourier series model to predict hourly heating

- and cooling energy use in commercial buildings with outdoor temperature as the only weather variable. 1999.
- [8] Lei, Fei and Hu, Pingfang. A baseline model for office building energy consumption in hot summer and cold winter region. in *2009 International Conference on Management and Service Science*, pp. 1–4. IEEE, 2009.
- [9] Ma, Yuan, Yu, Jun-qi, Yang, Chuang-ye, and Wang, Lei. Study on power energy consumption model for large-scale public building. in *2010 2nd International Workshop on Intelligent Systems and Applications*, pp. 1–4. IEEE, 2010.
- [10] Cho, Sung-Hwan, Kim, Won-Tae, Tae, Choon-Soeb, and Zaheeruddin, M. Effect of length of measurement period on accuracy of predicted annual heating energy consumption of buildings. *Energy conversion and management*, 45(18-19):2867–2878, 2004.
- [11] Lam, Joseph C, Wan, Kevin KW, Wong, SL, and Lam, Tony NT. Principal component analysis and long-term building energy simulation correlation. *Energy Conversion and Management*, 51(1):135–139, 2010.
- [12] Clarke, Joe A and Clarke, Joseph Andrew. *Energy Simulation in Building Design*. Routledge, 2001.
- [13] McQuiston, Faye C, Parker, Jerald D, and Spitler, Jeffrey D. *Heating, ventilating, and air conditioning: analysis and design*. John Wiley & Sons, 2004.
- [14] Al-Homoud, Mohammad Saad. Computer-aided building energy analysis techniques. *Building and Environment*, 36(4):421–433, 2001.
- [15] Kalogirou, Soteris A, Neocleous, CC, and Schizas, CN. Building heating load estimation using artificial neural networks. in *Proceedings of the 17th international con-*

- ference on Parallel architectures and compilation techniques*, vol. 8, p. 14. Citeseer, 1997.
- [16] Kalogirou, Soteris A. Artificial neural networks in energy applications in buildings. *International Journal of Low-Carbon Technologies*, 1(3):201–216, 2006.
- [17] Olofsson, Thomas, Andersson, Staffan, and Östin, Ronny. A method for predicting the annual building heating demand based on limited performance data. *Energy and Buildings*, 28(1):101–108, 1998.
- [18] Olofsson, Thomas and Andersson, Staffan. Long-term energy demand predictions based on short-term measured data. *Energy and Buildings*, 33(2):85–91, 2001.
- [19] Dong, Bing, Cao, Cheng, and Lee, Siew Eang. Applying support vector machines to predict building energy consumption in tropical region. *Energy and Buildings*, 37(5):545–553, 2005.
- [20] Lai, Florence, Magoules, Frederic, and Lherminier, Fred. Vapnik’s learning theory applied to energy consumption forecasts in residential buildings. *International Journal of Computer Mathematics*, 85(10):1563–1588, 2008.
- [21] Liang, Jian and Du, Ruxu. Model-based fault detection and diagnosis of hvac systems using support vector machine method. *International Journal of refrigeration*, 30(6):1104–1114, 2007.
- [22] Li, Qiong, Ren, Peng, and Meng, Qinglin. Prediction model of annual energy consumption of residential buildings. in *2010 international conference on advances in energy engineering*, pp. 223–226. IEEE, 2010.
- [23] Box, George EP, Jenkins, Gwilym M, Reinsel, Gregory C, and Ljung, Greta M. *Time series analysis: forecasting and control*. John Wiley & Sons, 2015.

- [24] Song, Qiang and Chissom, Brad S. Fuzzy time series and its models. *Fuzzy sets and systems*, 54(3):269–277, 1993.
- [25] Leake, David B. Cbr in context: The present and future. *Case-based reasoning: Experiences, lessons, and future directions*, pp. 3–30, 1996.
- [26] Schank, Roger C. *Dynamic memory: A theory of reminding and learning in computers and people*. cambridge university press, 1983.
- [27] Aamodt, Agnar and Plaza, Enric. Case-based reasoning: Foundational issues, methodological variations, and system approaches. *AI communications*, 7(1):39–59, 1994.
- [28] Azadeh, Ali, Ghaderi, Seyed F, Tarverdian, S, and Saberi, Morteza. Integration of artificial neural networks and genetic algorithm to predict electrical energy consumption. *Applied mathematics and computation*, 186(2):1731–1741, 2007.
- [29] Nie, Hongzhan, Liu, Guohui, Liu, Xiaoman, and Wang, Yong. Hybrid of arima and svms for short-term load forecasting. *Energy Procedia*, 16:1455–1460, 2012.
- [30] Chang, Pei-Chann, Fan, Chin-Yuan, and Lin, Jyun-Jie. Monthly electricity demand forecasting based on a weighted evolving fuzzy neural network approach. *International Journal of Electrical Power & Energy Systems*, 33(1):17–27, 2011.
- [31] Wang, Jujie, Wang, Jianzhou, Li, Yaning, Zhu, Suling, and Zhao, Jing. Techniques of applying wavelet de-noising into a combined model for short-term load forecasting. *International Journal of Electrical Power & Energy Systems*, 62:816–824, 2014.