



دانشگاه صنعتی امیرکبیر  
(پلی تکنیک تهران)  
دانشکده مهندسی کامپیوتر

گزارش نوشتاری درس روش پژوهش و ارائه

## بررسی الگوریتم‌های هوش مصنوعی در پیش‌بینی مصرف انرژی ساختمان‌ها

نگارش  
فرشید نوشی

استاد راهنما  
دکتر رضا صفا بخش

اردیبهشت ۱۴۰۱





دانشگاه صنعتی امیرکبیر  
(پلی تکنیک تهران)  
دانشکده مهندسی کامپیوتر

گزارش نوشتاری درس روش پژوهش و ارائه

## بررسی الگوریتم‌های هوش مصنوعی در پیش‌بینی مصرف انرژی ساختمان‌ها

نگارش  
فرشید نوشی

استاد راهنما  
دکتر رضا صفابخش

اردیبهشت ۱۴۰۱

تقدیم به پدر بزرگوار و مادر مهربانم

آن دو فرشته‌ای که از خواسته‌هایشان گذشتند، سختی‌ها را به جان خریدند و خود را سپر بلائی مشکلات و ناملایمات  
کردند تا من به جایگاهی که اکنون در آن ایستاده‌ام برسم.

# سپاس‌گزاری

به مصداق «من لم يشكر المخلوق لم يشكر الخالق» بسی شایسته است از استاد فرهیخته و فرزانه جناب آقای دکتر رضا صفابخش که با کرامتی چون خورشید، سرزمین دل را روشنی بخشیدند و گلشن‌سرای علم و دانش را با راهنمایی‌های کارساز و سازنده بارور ساختند تقدیر و تشکر نمایم.

فریدنوشی  
اردیبهشت ۱۴۰۱

## چکیده

پیش‌بینی مصرف انرژی برای ساختمان‌ها ارزش بسیار زیادی در تحقیقات بهره‌وری انرژی و پایداری دارد. مدل‌های پیش‌بینی دقیق انرژی، فواید متعددی در برنامه‌ریزی و بهینه‌سازی انرژی ساختمان‌ها و پردیس‌ها دارند. برای ساختمان‌های جدید، که در آن داده‌های ثبت شده گذشته در دسترس نیستند، از روش‌های شبیه‌سازی کامپیوتری برای تحلیل انرژی و پیش‌بینی سناریوهای آینده استفاده می‌شود. با این حال برای ساختمان‌های موجود با داده‌های انرژی سری زمانی ثبت‌شده گذشته، الگوریتم‌های آماری و هوش مصنوعی دقیق‌تر و سریع‌تر عمل کرده‌اند. این گزارش بررسی‌ای بر الگوریتم‌های هوش مصنوعی موجود برای پیش‌بینی مصرف انرژی سری زمانی انجام داده است. اگرچه تاکید بر یک تجزیه و تحلیل داده‌های سری زمانی منفرد است، اما بررسی فقط به آن محدود نمی‌شود زیرا داده‌های انرژی اغلب با سایر متغیرهای سری زمانی مانند آب‌وهوای بیرون و شرایط محیطی داخلی براساس روش محبوب پیش‌بینی که براساس یادگیری ماشین می‌باشد، تجزیه و تحلیل می‌شوند. یک بررسی از "مدل ترکیبی"، که ترکیبی از دو یا چند الگوریتم پیش‌بینی است نیز ارائه شده است. ترکیبات مختلف مدل ترکیبی موثرترین الگوریتم در پیش‌بینی انرژی سری زمانی برای ساختمان‌ها هستند.

## واژه‌های کلیدی:

یادگیری ماشین، هوش مصنوعی، پیش‌بینی داده‌های سری زمانی، مصرف انرژی ساختمان‌ها

# فهرست مطالب

صفحه

عنوان

۱	مقدمه	۱
۲	۱-۱ اهمیت بهینه سازی عملکرد ساختمان‌ها	۲
۴	۲-۱ اهداف بررسی	۴
۶	۲ روش‌های پیش‌بینی مصرف انرژی ساختمان‌ها	۶
۷	۱-۲ روش آماری	۷
۸	۲-۲ روش مهندسی	۸
۹	۳-۲ روش هوش مصنوعی	۹
۹	۱-۳-۲ شبکه‌های عصبی	۹
۱۰	۲-۳-۲ ماشین بردار پشتیبان	۱۰
۱۱	۴-۲ خلاصه	۱۱
۱۲	۳ مروری بر الگوریتم‌های هوش مصنوعی مورد بررسی	۱۲
۱۳	۱-۳ شبکه‌های عصبی مصنوعی	۱۳
۱۴	۲-۳ ماشین بردار پشتیبان	۱۴
۱۶	۳-۳ میانگین متحرک خودهمبسته یکپارچه	۱۶
۱۷	۴-۳ سری زمانی فازی	۱۷
۱۷	۵-۳ استدلال مبتنی بر مورد	۱۷
۱۷	۶-۳ مدل‌های ترکیبی	۱۷
۱۸	۷-۳ خلاصه	۱۸
۱۹	۴ ارزیابی نتایج تجربی بر روی مجموعه‌های داده	۱۹
۲۰	۱-۴ معیارهای ارزیابی	۲۰
۲۰	۲-۴ نتیجه‌ی روش‌های مورد بررسی	۲۰
۲۱	۳-۴ مقایسه و بررسی روش‌های معرفی شده	۲۱
۲۳	۴-۴ خلاصه	۲۳
۲۴	۵ نتیجه‌گیری و پیشنهادها	۲۴
۲۵	۱-۵ نتیجه‌گیری	۲۵
۲۶	۲-۵ پیشنهادها	۲۶
۲۸	منابع و مراجع	۲۸

شکل	فهرست اشکال	صفحه
۱-۱	اهمیت پیش‌بینی انرژی ساختمان‌ها برای بهینه‌سازی ساختمان‌ها	۵
۱-۳	پرسپترون	۱۳
۲-۳	شبکه‌ی عصبی مصنوعی	۱۴
۳-۳	ماشین بردار پشتیبان	۱۵
۴-۳	میانگین متحرک خودهمبسته یکپارچه	۱۶



صفحه	فهرست جداول	جدول
۱۱	۱-۲ خلاصه‌ی کلی از متدهای پیش‌بینی و ویژگی‌های هریک	
۲۱	۱-۴ نتیجه‌ی الگوریتم‌های هوش مصنوعی	

# فصل اول

## مقدمه

آژانس بین‌المللی انرژی، بهره‌وری انرژی در ساختمان‌ها را به عنوان یکی از پنج اقدام برای تضمین کربن‌زدایی طولانی مدت بخش انرژی شناسایی کرده است [۱] در کنار مزایای زیست محیطی، بهره‌وری انرژی ساختمان دارای مزایای اقتصادی گسترده ای نیز می‌باشد. ساختمان‌هایی با سیستم‌های انرژی کارآمد و استراتژی‌های مدیریتی هزینه‌های عملیاتی بسیار کمتری دارند. اکنون بسیاری از کشورها اجرای قوانین و مقررات انرژی را برای انواع ساختمان‌ها تسریع کرده‌اند. این مقررات الزامات اساسی برای دستیابی به یک طراحی کارآمد انرژی برای ساختمان‌های جدید با هدف کاهش مصرف انرژی نهایی و انتشار CO<sub>2</sub> مرتبط را ترسیم می‌کند. علاوه بر این، بسیاری از نرم افزارهای کامپیوتری نیز برای طراحی بهینه انرژی ساختمان‌های جدید توسعه یافته و به طور گسترده پیاده‌سازی شده‌اند. در مورد تکنیک‌های موجود تجزیه و تحلیل انرژی ساختمان به کمک کامپیوتر و ابزارهای نرم‌افزاری در [۲، ۳] اطلاعات دقیقی موجود هستند. این مقررات و ابزارهای کامپیوتری مربوط به ساختمان‌های جدید است و در واقع بسیار موثر هستند. با این حال، هنگامی که ساختمان در حال فعالیت است، عوامل زیادی بر رفتار انرژی یک ساختمان حاکم هستند، مانند شرایط آب و هوایی، برنامه حضور ساکنین ساختمان، خواص حرارتی مصالح ساختمانی، فعل و انفعالات پیچیده سیستم‌های انرژی مانند گرمایش و تهویه‌ها و روشنایی و غیره. به دلیل این فعل و انفعالات پیچیده، محاسبه دقیق مصرف انرژی از طریق مدل شبیه‌سازی کامپیوتری بسیار دشوار است. به این دلایل، تکنیک‌های داده‌محور برای تجزیه و تحلیل مصرف انرژی ساختمان‌های موجود بسیار حیاتی است. این تکنیک‌ها بر داده‌های ثبت‌شده گذشته تکیه دارند و تلاش می‌کنند مصرف انرژی را بر اساس الگوهای مصرف انرژی قبلی مدل‌سازی کنند. سایر عوامل مؤثر بر مصرف انرژی را می‌توان برای بهبود دقت چنین مدل‌های سری زمانی استفاده کرد. این تکنیک‌ها که از داده‌های گذشته استفاده می‌کنند، اغلب تحت «یادگیری ماشین» قرار می‌گیرند و در دو دهه اخیر به طور فعال در مطالعات پیش‌بینی انرژی ساختمان به کار رفته‌اند

## ۱-۱ اهمیت بهینه سازی عملکرد ساختمان‌ها [۱]

برای دستیابی به سطح بهینه عملکرد انرژی در ساختمان‌ها، نصب سیستم‌های انرژی کارآمد باید با استراتژی‌های عملیاتی و مدیریتی مناسب دنبال شود. این امر مستلزم نظارت و مدیریت مداوم داده‌های انرژی سری زمانی همراه با سایر عوامل مؤثر بر عملکرد انرژی ساختمان‌ها است. در رابطه با نظارت مستمر و مدیریت مصرف انرژی در ساختمان‌های موجود، پیش‌بینی نقش بسزایی دارد. می‌تواند مجموعه‌ای از شرایط مرزی و اهداف را برای مدیران و مالکان تأسیسات ساختمانی فراهم کند که مصرف انرژی ساختمان به طور ایده‌آل باید در آن قرار گیرد (هدف‌های روزانه، هفتگی، ماهانه و سالانه). همانطور که مدل پیش‌بینی سری‌های زمانی از الگوهای مصرف انرژی قبلی یاد می‌گیرد، افزایش تدریجی مقادیر مصرف انرژی پیش‌بینی‌شده در یک دوره زمانی ممکن است مدیران تأسیسات را در مورد جنبه‌های تعمیر و نگهداری ساختمان و سیستم‌های انرژی آگاه کند. علاوه بر رویکرد پیش‌بینی سری‌های زمانی، سایر رویکردهای سری غیرزمانی را می‌توان برای اهداف بهینه‌سازی ساختمان اتخاذ کرد و همچنین می‌توان

آنها را با سایر مدل‌های شبیه‌سازی کامپیوتری برای استخراج اشغال و سایر عوامل عملیاتی ترکیب کرد. یانگ<sup>۱</sup> و همکاران در بهینه‌سازی انرژی مبتنی بر شبیه‌سازی برای یک ساختمان آزمایشی در اسپانیا، یک چارچوب بهینه‌سازی الگوریتم ژنتیک موازی مبتنی بر وب<sup>۲</sup> که از منابع محاسباتی توزیع‌شده استفاده می‌کند تا زمان محاسبه را کاهش دهد استفاده کردند. پتری<sup>۳</sup> و همکاران یک سیستم بهینه‌سازی مبتنی بر مدولار ارائه کردند که شبیه‌سازی انرژی و بهینه‌سازی را با استفاده از شبکه عصبی مصنوعی ترکیب می‌کند. این برنامه کاهش قابل توجه انرژی (کیلووات ساعت) را در یک سناریوی واقعی نشان داد. با این حال، این امر مستلزم تجهیز ساختمان به حسگرها و عملگرها برای نظارت، کنترل و بهینه‌سازی بود. این ممکن است در مورد اکثر زیرساخت‌های ساختمان موجود نباشد. چنین چالش‌هایی مورد بحث قرار می‌گیرند. با این حال، همچنین خاطرنشان می‌شود که پتانسیل صرفه جویی انرژی مرتبط در ساختمان‌ها به راه اندازی، ردیابی عملکرد و استراتژی‌های کنترل پیشرفته مربوط می‌شوند. این امر به عوامل بسیاری از جمله منابع مالی، حمایت از سیاست، آگاهی سبز، مواد سبز و فناوری و غیره وابسته است.

زونگ<sup>۴</sup> و همکاران در مورد چالش‌های اجرای یک مدل اقتصادی استراتژی کنترل پیش‌بینی<sup>۵</sup> برای ساختمان‌های هوشمند بحث کردند. مشاهده شد که هنوز چالش‌هایی در کاربرد کنترل پیش‌بینی مدل از جمله سازش بین ساده‌سازی و پیچیدگی مدل‌سازی دینامیکی حرارتی ساختمان و تعادل بین سیستم‌های چند انرژی وجود دارد. هو و همکاران با درک چالش‌ها در ادغام داده‌های عملکرد ساختمان با سایر داده‌های مربوط به ساختمان. روش جدیدی را برای پیوند دادن داده‌های قطع شده سنتی برای ساخت منابع داده ارائه کرد تا ارزیابی عملکرد ساختمان را به صورت عمیق و روشن‌تر فراهم کند. پیش‌بینی سری‌های زمانی برای بهینه‌سازی عملکرد ساختمان ضروری است. هر تکنیک بهینه‌سازی به اطلاعاتی در مورد سناریوهای آینده یا یافتن بهترین راه‌حل‌ها در برابر یک معیار آزمایشی نیاز دارد. تکنیک‌های یادگیری ماشین در این زمینه مفید هستند و اغلب در حل این دو مشکل استفاده می‌شوند. با این حال، این بررسی بر جنبه‌های پیش‌بینی سری‌های زمانی بهینه‌سازی ساختمان تمرکز دارد تا اینکه به طور کلی به مسئله بهینه‌سازی نگاه کند. ادغام این دو باید در یک بررسی جداگانه مورد بررسی قرار گیرند.

Yang<sup>۱</sup>GA<sup>۲</sup>Petri<sup>۳</sup>Zong<sup>۴</sup>EMPC<sup>۵</sup>

## ۲-۱ اهداف بررسی [۱]

مطالعات بررسی اخیر در مورد پیش بینی انرژی، گزارش‌های دقیقی از مدل‌های پیش‌بینی موجود و طبقه‌بندی آنها ارائه می‌دهد. ژائو<sup>۶</sup> و ماگولس<sup>۷</sup> روش‌های موجود برای پیش‌بینی مصرف انرژی ساختمان را در پنج دسته بررسی و طبقه‌بندی کردند. هیپرت<sup>۸</sup> و همکاران مروری بر پیش‌بینی بار کوتاه مدت ارائه کرد. سوگانتی<sup>۹</sup> و ساموئل<sup>۱۰</sup> مروری بر مدل‌های تقاضای انرژی برای پیش‌بینی تقاضا ارائه کردند. فومو<sup>۱۱</sup> مروری بر برآورد انرژی ساختمان ارائه کرد و همچنین نحوه طبقه‌بندی مدل‌های برآورد را مورد مطالعه قرار داد. مارتینز-آلوارز<sup>۱۲</sup> و همکاران یک نظرسنجی در مورد تکنیک‌های داده‌کاوی برای پیش‌بینی سری‌های زمانی الکترونیسته ارائه کرد. این نظرسنجی بر روی ویژگی‌های مدل‌ها و پیکربندی آنها متمرکز بود. رضا و خسروی مروری بر تکنیک‌های پیش‌بینی بار کوتاه‌مدت بر اساس تکنیک‌های هوش مصنوعی ارائه کردند. مطالعه اخیر توسط مت داوت<sup>۱۳</sup> و همکاران مروری بر تحلیل پیش‌بینی مصرف انرژی الکتریکی ساختمان با استفاده از روش‌های مرسوم و هوش مصنوعی ارائه کرد. همه این بررسی‌ها اطلاعات حیاتی در مورد مدل‌های پیش‌بینی انرژی در مقیاس‌های مختلف ارائه می‌کنند و بر عملکرد برتر مدل‌های ترکیبی تأکید می‌کنند. یک مدل پیش‌بینی می‌تواند مبتنی بر داده‌های استاتیکی باشد که معمولاً یک متغیر وابسته را با مجموعه‌ای از متغیرهای مستقل منطبق می‌کند، یا می‌تواند از داده‌های سری زمانی منفرد یا موازی استفاده کند.

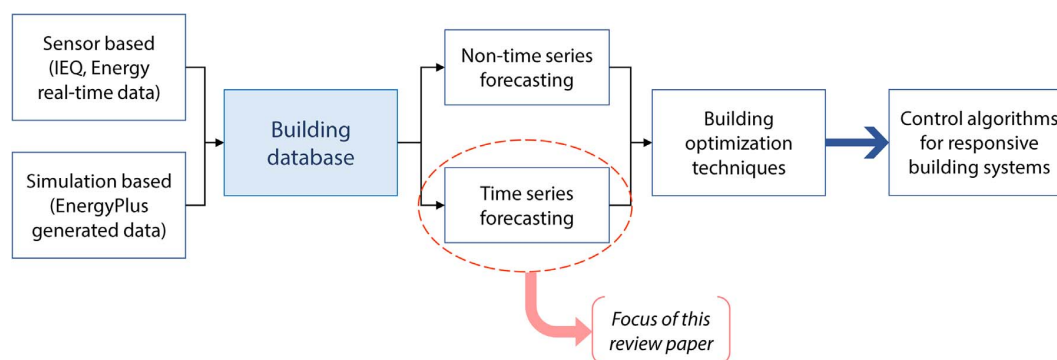
این مطالعه بر تکنیک‌های پیش‌بینی با استفاده از داده‌های سری زمانی تأکید دارد. اهمیت تجزیه و تحلیل سری‌های زمانی به دلیل افزایش آگاهی در جمع‌آوری و پایش داده‌ها در زمان واقعی است. مصرف انرژی سری زمانی را نیز می‌توان با داده‌های سری زمانی شرایط محیطی داخل ساختمان تنظیم کرد. با استقرار حسگرهای بیشتر در ساختمان‌ها و جمع‌آوری داده‌های سری زمانی بیشتر، یک چارچوب مناسب برای تجزیه و تحلیل و شناسایی قابلیت‌های پیش‌بینی مهم است. هدف این بررسی درک تکنیک‌های پیش‌بینی سری‌های زمانی موجود و ارائه مزایا و چالش‌های آنها است. ارزیابی دقیق مدل ترکیبی نیز به دلیل استفاده فزاینده در ادبیات ارائه شده است. از آنجایی که ترکیبات مدل ترکیبی بسیار زیاد است، اینها در بخش بعدی پس از بررسی انتقادی تکنیک‌های اصلی مانند شبکه‌ی عصبی مصنوعی<sup>۱۴</sup> و میانگین متحرک خودهمبسته یکپارچه<sup>۱۵</sup> مورد بررسی انتقادی قرار می‌گیرند. این مقاله مروری همچنین باید مبنایی برای مقایسه کیفی و کمی برای تمام ۶ تکنیک ذکر شده در اینجا فراهم

Zhao<sup>۶</sup>Magoules<sup>۷</sup>Hippert<sup>۸</sup>Suganthi<sup>۹</sup>Samuel<sup>۱۰</sup>Fumo<sup>۱۱</sup>Martinez-Alvarez<sup>۱۲</sup>Mat Daut<sup>۱۳</sup>artificial neural network<sup>۱۴</sup>ARIMA<sup>۱۵</sup>

کند. شایان ذکر است که مدل ترکیبی به عنوان یکی از تکنیک های موجود در بین ۶ تکنیک ارائه شده در نظر گرفته شده است. در مدل ترکیبی، در مجموع ۲۹ ترکیب وجود دارد که در این بررسی به آنها پرداخته شده است

اهداف این مقاله مروری عبارتند از:

- ارائه بررسی ای جمعی و جامع از تکنیک های اصلی هوش مصنوعی پیش بینی سری های زمانی با توجه به مصرف انرژی ساختمان
- انجام یک تحلیل تطبیقی که شامل هر دو جنبه کیفی و کمی این تکنیک ها باشد
- تشریح ترکیبات مختلف مدل ترکیبی در حین ارزیابی عملکرد و تازگی آنها



شکل ۱-۱ تمرکز این گزارش نوشتاری در حوزه بهینه سازی ساختمان [۱]

در فصل های بعدی نخست توضیحاتی در مورد پیش بینی مصرف انرژی ساختمان ها می دهیم و در مورد روش های تاریخی و قدیمی تر از الگوریتم های هوش مصنوعی صحبت خواهیم کرد که روش های مهندسی و آماری را شامل میشوند. در فصل ۳ الگوریتم های متنوع هوش مصنوعی برای پیش بینی سری داده های زمانی معرفی و به طور مفصل شرح داده میشوند و هر یک معادلات مورد نیازشان توضیح داده میشود. در فصل ۴ معیارهای سنجش بین این الگوریتم ها معرفی می شوند و آزمایش های متنوع برای یافتن الگوریتم های مناسب را گزارش می دهیم و در نهایت در فصل ۵ با نتیجه گیری از مطالب گفته شده سعی در نتیجه گیری گزارش و ارائه پیشنهادات مناسب شده است.

## فصل دوم

روش‌های پیش‌بینی مصرف انرژی

ساختمان‌ها

پیش‌بینی داده‌های سری زمانی از زمان گذشته مورد توجه محققین و متخصصین بوده است. در نتیجه در گذر زمان روش‌های متنوعی برای این موضوع پیشنهاد شده‌اند. آمار و احتمالات از علوم بسیار قدیمی بشریت محسوب می‌شود یکی از روش‌های قدیمی برای پیش‌بینی داده‌های سری زمانی می‌باشد در کنار این روش، روش‌های مهندسی نیز در دهه‌های گذشته استفاده شده‌اند. در این فصل برای ارائه یک دید جامع و مناسب در مورد پیش‌بینی مصرف انرژی ساختمان‌ها در مورد هر دو روش گفته شده صحبت می‌کنیم و در نهایت در مورد روش‌های هوش مصنوعی توضیحاتی را ارائه می‌کنیم.

## ۱-۲ روش آماری

مدل‌های رگرسیون آماری صرفاً مصرف انرژی یا شاخص انرژی را با متغیرهای تأثیرگذار مرتبط می‌کنند. این مدل‌های تجربی از داده‌های عملکرد تاریخی ایجاد شده‌اند، به این معنی که قبل از آموزش مدل‌ها، باید داده‌های تاریخی کافی را جمع‌آوری کنیم. تحقیقات زیادی بر روی مدل‌های رگرسیون در مورد مسائل زیر انجام شده است. اولین مورد پیش‌بینی مصرف انرژی بر روی متغیرهای ساده شده مانند یک یا چند پارامتر آب و هوا است. مورد دوم پیش‌بینی برخی از شاخص انرژی مفید است. مورد سوم، تخمین پارامترهای مهم مصرف انرژی، مانند ضریب تلفات حرارتی کل، ظرفیت حرارتی کل و ضریب افزایش است که در تحلیل رفتار حرارتی ساختمان یا سیستم‌های سطح فرعی مفید هستند.

در برخی از مدل‌های مهندسی ساده‌شده، از رگرسیون برای ارتباط مصرف انرژی با متغیرهای آب و هوایی برای به دست آوردن امضای انرژی استفاده می‌شود [۴، ۵]. بائر<sup>۱</sup> و اسکارتزینی<sup>۲</sup> [۵] یک روش رگرسیون را برای انجام محاسبات گرمایش و سرمایش به طور همزمان با پرداختن به سودهای داخلی و همچنین خورشیدی پیشنهاد کردند. دار<sup>۳</sup> و همکاران [۶، ۷] بار گرمایش و سرمایش را در ساختمان‌های تجاری با دمای حباب خشک در فضای باز به عنوان تنها متغیر آب و هوا مدل‌سازی کرد. یک مدل سری فوریه مبتنی بر دما برای نشان دادن وابستگی غیرخطی بارهای گرمایش و سرمایش به زمان و دما پیشنهاد شد. اگر داده‌های رطوبت و خورشید نیز در دسترس باشد، آنها استفاده از مدل سری فوریه تعمیم‌یافته را پیشنهاد کردند زیرا ارتباط مهندسی بیشتر و توانایی پیش‌بینی بالاتری دارد. همچنین با در نظر گرفتن دمای حباب خشک به عنوان متغیر واحد برای توسعه مدل، لی<sup>۴</sup> و هو<sup>۵</sup> [۸] مدل‌های رگرسیونی را برای پیش‌بینی صرفه‌جویی در انرژی از پروژه‌های مقاوم‌سازی ساختمان‌های اداری در یک منطقه تابستانی گرم و زمستانی سرد ارزیابی کردند. آنها نشان دادند که یک مدل خطی تک متغیری برای مدل‌سازی مصرف انرژی در شرایط آب و هوایی گرم و سرد کافی و کاربردی است. ما<sup>۶</sup> و همکاران [۹] روش‌های رگرسیون خطی چندگانه و خود رگرسیون را برای پیش‌بینی مصرف انرژی ماهانه برای ساختمان‌های

Bauer<sup>۱</sup>Scartezini<sup>۲</sup>Dhar<sup>۳</sup>Lei<sup>۴</sup>Hu<sup>۵</sup>Ma<sup>۶</sup>



عمومی در مقیاس بزرگ ادغام کرد. در کار چو<sup>۷</sup> و همکاران [۱۰]، مدل رگرسیون در اندازه‌گیری‌های ۱ روزه، ۱ هفته‌ای و ۳ ماهه ایجاد شد که منجر به خطای پیش‌بینی در مصرف انرژی سالانه ۱۰۰٪، ۳۰٪، ۶٪ شد. این نتایج نشان می‌دهد که طول دوره اندازه‌گیری به شدت بر مدل‌های رگرسیون وابسته به دما تأثیر می‌گذارد.

در مورد پیش‌بینی شاخص انرژی، لام<sup>۸</sup> و همکاران [۱۱] از تجزیه و تحلیل اجزای اصلی<sup>۹</sup> برای ایجاد یک شاخص آب و هوایی زد<sup>۱۰</sup> با توجه به تابش خورشیدی جهانی، دمای حباب خشک و مرطوب استفاده کرد. آنها دریافتند که زد<sup>۱۰</sup> همان روندی را دارد که بار سرمایشی شبیه‌سازی شده، تهویه مطبوع و مصرف انرژی ساختمان را نشان می‌دهد. این روند از تحلیل همبستگی با تحلیل رگرسیون خطی به دست آمد. این مدل بر اساس داده‌های ۱۹۷۹ تا ۲۰۰۷ توسعه یافته است.

## ۲-۲ روش مهندسی

روش‌های مهندسی از اصول فیزیکی برای محاسبه دینامیک حرارتی و رفتار انرژی در کل سطح ساختمان یا برای اجزای سطح فرعی استفاده می‌کنند. آنها در طول پنجاه سال گذشته به اندازه کافی توسعه یافته‌اند. این روش‌ها را می‌توان به طور تقریبی به دو دسته روش جامع تفصیلی و روش ساده شده طبقه‌بندی کرد. روش‌های جامع از توابع فیزیکی بسیار دقیق یا دینامیک حرارتی برای محاسبه دقیق، گام به گام، مصرف انرژی برای همه اجزای ساختمان با اطلاعات ساختمان و محیط‌زیست، مانند شرایط اقلیمی خارجی، ساخت و ساز ساختمان، بهره‌برداری، برنامه نرخ بهره‌برداری استفاده می‌کنند. و تجهیزات گرمایش و تهویه هوا به عنوان ورودی. در این مقاله، ما بر دیدگاه جهانی مدل‌ها و برنامه‌ها تمرکز می‌کنیم، در حالی که جزئیات این فرآیندهای محاسباتی بسیار فراتر از هدف این بررسی است. خوانندگان ممکن است برای جزئیات محاسبه به [۱۲] مراجعه کنند. برای سیستم‌های گرمایش و تهویه هوا، به طور خاص، محاسبه دقیق انرژی در [۱۳] معرفی شده است. سازمان بین‌المللی استاندارد سازی، استاندارد برای محاسبه مصرف انرژی برای گرمایش و سرمایش فضا برای یک ساختمان و اجزای آن ایجاد کرده است. صدها ابزار نرم افزاری برای ارزیابی کارایی انرژی، انرژی‌های تجدیدپذیر و پایداری در ساختمان‌ها توسعه یافته‌اند. برخی از آنها به طور گسترده برای توسعه استانداردهای انرژی ساختمان و تجزیه و تحلیل مصرف انرژی و اقدامات حفاظتی ساختمان‌ها مورد استفاده قرار گرفته‌اند. این ابزارها در مقاله‌های [۳، ۱۴] بررسی شده‌اند. وزارت انرژی ایالات متحده فهرستی از تقریباً تمام ابزارهای شبیه‌سازی را که دائماً به روز می‌شود، نگهداری می‌کند.

اگرچه این ابزارهای شبیه‌سازی دقیق موثر و دقیق هستند، اما در عمل مشکلاتی وجود دارد. از آنجایی که این ابزارها مبتنی بر اصول فیزیکی هستند، برای رسیدن به یک شبیه‌سازی دقیق، به جزئیات ساختمان

Cho<sup>۷</sup>  
Lam<sup>۸</sup>  
PCA<sup>۹</sup>  
Z<sup>۱۰</sup>

و پارامترهای محیطی به عنوان داده‌های ورودی نیاز دارند. از یک طرف، این پارامترها برای بسیاری از سازمان‌ها در دسترس نیستند، به عنوان مثال، اطلاعات مربوط به هر اتاق در یک ساختمان بزرگ همیشه دشوار است. این عدم وجود ورودی‌های دقیق منجر به شبیه‌سازی با دقت پایین می‌شود. از سوی دیگر، به کارگیری این ابزارها معمولاً نیازمند کار کارشناسی خسته‌کننده است که انجام آن را دشوار و هزینه‌بر می‌کند. به این دلایل برخی از محققان مدل‌های ساده‌تری را برای ارائه جایگزین‌هایی برای کاربردهای خاص پیشنهاد کرده‌اند.

الحمود<sup>۱۱</sup> [۱۴] دو روش ساده شده را بررسی کرد. یکی روش درجه روز است که در آن تنها یک شاخص یعنی درجه روز تحلیل می‌شود. این روش حالت پایدار برای تخمین مصرف انرژی ساختمان‌های کوچک که در آن انرژی مبتنی بر پوشش غالب است، مناسب است. یکی دیگر از سطل، همچنین به عنوان روش فرکانس دما شناخته می‌شود، که می‌تواند برای مدل‌سازی ساختمان‌های بزرگ استفاده شود که در آن بارهای تولید شده داخلی غالب هستند یا بارها به طور خطی به اختلاف دمای بیرون و داخل خانه وابسته نیستند.

شرایط آب و هوایی عوامل مهمی برای تعیین میزان مصرف انرژی ساختمان هستند. اینها اشکال مختلفی مانند دما، رطوبت، تابش خورشیدی، سرعت باد دارند و در طول زمان تغییر می‌کنند. مطالعات خاصی برای ساده کردن شرایط آب و هوایی در محاسبات انرژی ساختمان انجام شده است.

## ۲-۳ روش هوش مصنوعی

روش‌های هوش مصنوعی در سال‌های اخیر رشد در زمینه‌ی پیش‌بینی مصرف انرژی ساختمان‌ها رشد بسیار زیادی داشته‌اند. به علت سهولت بهتر و دقت بالای این روش در سال‌های اخیر روش غالب در پیش‌بینی مصرف انرژی ساختمان‌ها این نوع روش‌ها بوده‌اند. در این بخش دو زیربخش مهم از روش‌های هوش مصنوعی مورد بررسی قرار گرفته‌اند.

### ۲-۳-۱ شبکه‌های عصبی<sup>۱۲</sup>

شبکه‌های عصبی مصنوعی پرکاربردترین مدل‌های هوش مصنوعی در کاربرد پیش‌بینی انرژی ساختمان هستند. این نوع مدل در حل مسائل غیر خطی خوب است و یک رویکرد موثر برای این کاربرد پیچیده است. در بیست سال گذشته، محققان از شبکه‌های عصبی مصنوعی برای تجزیه و تحلیل انواع مختلف مصرف انرژی ساختمان در شرایط مختلف، مانند بار گرمایش/سرمایش، مصرف برق، عملکرد و بهینه‌سازی اجزای سطح زیرین، تخمین پارامترهای مصرف استفاده کرده‌اند. در این بخش، مطالعات قبلی را مرور می‌کنیم و با توجه به کاربردهایی که به آن پرداخته شده، آنها را در گروه‌هایی قرار می‌دهیم. علاوه بر این، بهینه‌سازی مدل، مانند پیش‌فرآیند داده‌های ورودی و مقایسه بین شبکه‌های عصبی مصنوعی و

<sup>۱۱</sup> Al-Homoud

<sup>۱۲</sup> Neural Networks

سایر مدل‌ها، در پایان برجسته شده است. در سال ۲۰۰۶، کالوگرو<sup>۱۳</sup> [۱۵] مروری کوتاه بر شبکه‌های عصبی مصنوعی در کاربردهای انرژی در ساختمان‌ها، از جمله سیستم‌های گرمایش آب خورشیدی، تابش خورشیدی، سرعت باد، توزیع جریان هوا در داخل اتاق، پیش‌بینی مصرف انرژی، دمای هوای داخل ساختمان و سیستم گرمایش و تهویه هوا انجام داد. کالوگرو<sup>۱۸</sup> و همکاران [۱۶] از شبکه‌های عصبی پس‌انتشار<sup>۱۴</sup> برای پیش‌بینی بار گرمایش مورد نیاز ساختمان‌ها استفاده کرد. این مدل بر روی داده‌های مصرف ۲۲۵ ساختمان آموزش داده شد که تا حد زیادی از فضاهای کوچک تا اتاق‌های بزرگ متفاوت است. اولوفسون و همکاران [۱۷] تقاضای گرمایش سالانه تعدادی از ساختمان‌های کوچک خانواده‌ای در شمال سوئد را پیش‌بینی کرد. بعداً، اولوفسون<sup>۱۵</sup> و اندرسون<sup>۱۶</sup> [۱۸] یک شبکه عصبی ایجاد کردند که تقاضای انرژی بلندمدت (تقاضای گرمایش سالانه) را بر اساس داده‌های اندازه‌گیری شده کوتاه‌مدت (معمولاً ۲ تا ۵ هفته) با نرخ پیش‌بینی بالا برای ساختمان‌های تک خانواده پیش‌بینی می‌کند.

## ۲-۳-۲ ماشین بردار پشتیبان<sup>۱۷</sup>

ماشین‌های بردار پشتیبان به طور فزاینده‌ای در تحقیقات و صنعت مورد استفاده قرار می‌گیرند. آنها مدل‌های بسیار موثری در حل مسائل غیر خطی حتی با مقادیر کم داده‌های آموزشی هستند. مطالعات بسیاری از این مدل‌ها در مورد تجزیه و تحلیل انرژی ساختمان در پنج سال گذشته انجام شده است. دونگ<sup>۱۸</sup> و همکاران [۱۹] برای اولین بار از ماشین بردار پشتیبان برای پیش‌بینی مصرف برق ماهانه چهار ساختمان در منطقه گرمسیری استفاده کرد. داده‌های سه ساله آموزش داده شد و مدل مشتق شده برای پیش‌بینی سودمندی مالک در آن سال بر روی داده‌های یک ساله اعمال شد. نتایج نشان دهنده عملکرد خوب ماشین‌های بردار پشتیبان در این مشکل بود.

لای<sup>۱۹</sup> و همکاران [۲۰] این مدل را بر مصرف برق یکساله یک ساختمان اعمال کرد. متغیرها شامل تغییرات آب و هوایی است. در آزمایشات آنها، این مدل از عملکرد یک سال استخراج شد و سپس بر روی رفتار سه ماهه آزمایش شد. آنها همچنین مدل را بر روی هر مجموعه داده روزانه آزمایش کردند تا پایداری این رویکرد را در دوره‌های کوتاه تأیید کنند. علاوه بر این، آنها اغتشاش را به صورت دستی به بخش خاصی از عملکرد تاریخی اضافه کردند و از این مدل برای تشخیص اغتشاش با بررسی تغییر وزن‌های کمک‌کننده استفاده کردند.

لیانگ<sup>۲۰</sup> و دو<sup>۲۱</sup> [۲۱] یک روش تشخیص عیب مقرون به صرفه را برای سیستم‌های گرمایش و تهویه

Kalogirou<sup>۱۳</sup>

back propagation neural networks<sup>۱۴</sup>

Olofsson<sup>۱۵</sup>

Anderson<sup>۱۶</sup>

Support Vector Machine(SVM)<sup>۱۷</sup>

Dong<sup>۱۸</sup>

Lai<sup>۱۹</sup>

Liang<sup>۲۰</sup>

Du<sup>۲۱</sup>

متد	پیچیدگی مدل	سادگی استفاده	سرعت اجرا	نیازهای ورودی	دقت
مهندسی دقیق	نسبتاً بالا	غیر ساده	کم	با جزئیات	نسبتاً بالا
مهندسی ساده سازی شده	بالا	ساده	بالا	ساده سازی شده	بالا
آماري	معمولی	ساده	نسبتاً بالا	داده‌های تاریخی	معمولی
شبکه‌های عصبی مصنوعی	بالا	غیر ساده	بالا	داده‌های تاریخی	بالا
ماشین بردار پشتیبان	نسبتاً بالا	غیر ساده	کم	داده‌های تاریخی	نسبتاً بالا

جدول ۱-۲ خلاصه‌ی کلی از متدهای پیش‌بینی و ویژگی‌های هریک

هوا با ترکیب مدل فیزیکی و یک ماشین بردار پشتیبان ارائه کردند. با استفاده از طبقه‌بندی کننده چهار لایه ماشین بردار پشتیبان، می‌توان وضعیت عادی و سه خطای احتمالی را با تعداد کمی از نمونه‌های آموزشی به سرعت و با دقت تشخیص داد.

## ۴-۲ خلاصه

با توجه به توصیف و تحلیل فوق، بدیهی است که برای ارزیابی سیستم انرژی ساختمان، از سطح زیرسیستم تا سطح ساختمان و حتی سطح منطقه ای یا ملی، محاسبات زیادی مورد نیاز است. هر مدل در موارد خاصی از کاربردها مزایای خاص خود را دارد. مدل مهندسی تغییرات زیادی را نشان می‌دهد. ملاحظات زیادی می‌تواند در توسعه این مدل دخیل باشد. می‌تواند یک مدل بسیار پیچیده و جامع باشد که برای محاسبات دقیق قابل استفاده است. در مقابل، با اتخاذ برخی استراتژی‌های ساده‌کننده، می‌توان آن را به یک مدل سبک تبدیل کرد و با حفظ دقت، توسعه آن آسان است. یک اشکال رایج پذیرفته شده این مدل مهندسی دقیق این است که به دلیل پیچیدگی زیاد و کمبود اطلاعات ورودی، اجرای آن در عمل دشوار است. توسعه مدل آماری نسبتاً آسان است اما اشکالات آن نیز مشهود است که عبارتند از عدم دقت و عدم انعطاف پذیری. شبکه‌های عصبی مصنوعی و ماشین‌های بردار پشتیبان در حل مسائل غیر خطی خوب هستند و آنها را برای پیش‌بینی انرژی ساختمان کاربردی می‌کند. تا زمانی که انتخاب مدل و تنظیم پارامترها به خوبی انجام شود، آنها می‌توانند پیش‌بینی بسیار دقیقی ارائه دهند. ماشین‌های بردار پشتیبان حتی در بسیاری از موارد عملکرد بهتری نسبت به شبکه‌های عصبی مصنوعی نشان می‌دهند [۲۲]. معایب این دو نوع مدل این است که به داده‌های عملکرد تاریخی کافی نیاز دارند و بسیار پیچیده هستند. تجزیه و تحلیل مقایسه‌ای این مدل‌های رایج در جدول ۱ خلاصه شده است.


## فصل سوم

# مروری بر الگوریتم‌های هوش مصنوعی مورد بررسی

در این بخش می‌خواهیم با انجام یک مرور بر روی الگوریتم‌های مختلف هوش مصنوعی که برای پیش‌بینی کردن داده‌های سری زمانی معمولاً مورد استفاده قرار می‌گیرند آشنایی کلی با هریک از آن‌ها به‌دست بیاوریم. بخش بزرگی از مسئولیت پیش‌بینی داده‌های سری زمانی برعهده ی یادگیری ماشین که خود یک بخش بزرگ از هوش مصنوعی می‌باشد هست. از جمله الگوریتم‌های مهم در این بخش شبکه‌های عصبی مصنوعی، ماشین‌های بردار پشتیبان، میانگین متحرک خودهمبسته یکپارچه، سری زمانی فازی و استدلال مبتنی بر مورد هستند. در نهایت در پایان این بخش خلاصه ای از آنچه تا به حال در مورد این الگوریتم‌ها گفته شد خواهد آمد.

### ۱-۳ شبکه‌های عصبی مصنوعی

شبکه‌های عصبی مصنوعی یک دسته از مدل‌های غیرخطی و غیرپارامتری هستند که برای تقریب عملکردهای غیرخطی و چندمتغیره عمومی آموزش داده میشوند. این نوع شبکه‌ها سیستم‌های کاملاً موازی هستند که از عناصر پردازشی به هم پیوسته به نام پرسپترون تشکیل شده‌اند. (پرسپترون یک شبیه سازی پایه ای از نورون مغز انسان هست) یکی از مزایای اصلی شبکه‌های عصبی در مقایسه با مدل‌های دیگر عدم نیاز آن‌ها به داشتن فرضیات خاص می‌باشد. در شکل ۱-۳ از یک پرسپترون آمده است که نحوه ی کارکرد آن به طور کلی با تابع ریاضی زیر مدل میشود.




شکل ۱-۳ پرسپترون

$$output = f(\sum_{i=1}^n (x_i * w_i) + w_0) \quad (1-3)$$

در معادله ی ۱-۳ ورودی‌های پرسپترون برابر با  $x$  هستند و به تعداد ورودی‌های پرسپترون وزن‌های  $w_i$  در ۱-۳ ورودی‌ها ضرب شده و حاصل جمع این عبارت به یک تابع فعال‌سازی در پرسپترون داده میشود. که در معادله ی بالا این تابع فعال‌سازی  $f(x)$  فرض شده است.

شبکه‌ی عصبی مجموعه‌ای چندلایه از این پرسپترون‌ها می‌باشد که پرسپترون‌های هرلایه به تمام پرسپترون‌های لایه‌ی بعدی وصل شده و لایه‌ی ورودی ورودی‌های مسئله‌ی ما هستند و خروجی شبکه‌ی عصبی نیز خروجی خواسته شده‌ی ما هست. در شکل ۲-۳ یک شبکه‌ی عصبی نمونه آورده شده است.



شکل ۲-۳ شبکه‌ی عصبی مصنوعی

## ۲-۳ ماشین بردار پشتیبان

بر اساس اصل به حداقل رساندن خطر ساختاری از نظریه یادگیری آماری، ماشین بردار پشتیبان در ابتدا برای حل مسئله شناسایی الگوی دو طبقه معرفی شد. ایده اصلی ساخت یک جداکننده است که در حالی که کوچکترین حاشیه را به حداکثر می‌رساند (به عنوان مثال برای دستیابی به بزرگترین حاشیه از دو کلاس داده)، موارد مثبت و منفی را از هم جدا می‌کند. ماشین بردار پشتیبان دو مزیت مهم دارد:

۱. انتخاب ویژگی اغلب مورد نیاز نیست، زیرا نسبت به بیشبرازش نسبتاً قوی است و میتواند تا ابعاد بالا را مقیاسبندی کند.


۲. هیچ تلاشی در تنظیم پارامتر لازم نیست، زیرا نشان داده شده است که گزینه‌ی "پیش فرض" از لحاظ نظری، برای تنظیم بیشترین اثربخشی ارائه میشود

از ماشین بردار پشتیبان برای حل دو نوع مسئله‌ی طبقه بندی و رگرسیون استفاده میشود. این روش در سال‌های گذشته عملکرد مناسبی در این دو مسئله داشته است. این روش از جمله روش‌های نسبتاً جدیدی است که در سال‌های اخیر کارایی خوبی نسبت به روش‌های قدیمی‌تر برای طبقه‌بندی نشان داده‌است. مبنای کاری دسته‌بندی کننده ماشین بردار پشتیبان دسته‌بندی خطی داده‌ها است و در تقسیم خطی داده‌ها سعی می‌کنیم خطی را انتخاب کنیم که حاشیه اطمینان بیشتری داشته باشد. قبل

از تقسیم خطی برای اینکه ماشین بتواند داده‌های با پیچیدگی بالا را دسته‌بندی کند داده‌ها را به وسیله تابع  $\phi$  به فضای با ابعاد خیلی بالاتر می‌بریم. برای اینکه بتوانیم مسئله ابعاد خیلی بالا را با استفاده از این روش‌ها حل کنیم از قضیه دوگانگی لاگرانژ برای تبدیل مسئله مینیمم‌سازی مورد نظر به فرم دوگانگی آن که در آن به جای تابع پیچیده  $\phi$  که ما را به فضایی با ابعاد بالا می‌برد، تابع ساده‌تری به نام تابع هسته که ضرب برداری تابع  $\phi$  است ظاهر می‌شود استفاده می‌کنیم. از توابع هسته مختلفی از جمله هسته‌های نمایی، چندجمله‌ای و سیگموئید می‌توان استفاده نمود.

به طور خلاصه برای ماشین بردار پشتیبان باید ماتریس الگو را آماده می‌کنیم. تابع کرنلی را برای استفاده انتخاب می‌کنیم. پارامتر تابع کرنل و مقدار  $C$  را انتخاب می‌کنیم. برای محاسبه مقادیر  $a_i$  الگوریتم آموزشی را با استفاده از حل‌کننده‌های  $QP$  اجرا می‌کنیم. داده‌های جدید با استفاده از مقادیر  $a_i$  و بردارهای پشتیبان می‌توانند دسته‌بندی شوند.

هدف ماشین بردار پشتیبان به مانند شکل ۳-۳ پیدا کردن دو ابرصفحه در حاشیه‌ی دو دسته از داده‌ها است که از یکدیگر بیشترین فاصله ی ممکن را داشته باشند.



شکل ۳-۳ ماشین بردار پشتیبان



### ۳-۳ میانگین متحرک خودهمبسته یکپارچه<sup>۱</sup>

مدل‌های میانگین متحرک خودهمبسته یکپارچه<sup>۱</sup> اساسی‌ترین و عمومی‌ترین شکل تکنیک‌های پیش‌بینی سری‌های زمانی هستند. اینها بر اساس ایده تبدیل سری‌های زمانی به ثابت بودن توسط فرآیند تفاضل هستند. اگر خصوصیات آماری آن در طول زمان ثابت باشند، می‌توان سری زمانی را ثابت فرض کرد. بنابراین، معادله میانگین متحرک خودهمبسته برای یک سری زمانی، یک معادله خطی است که ورودی آن شامل تأخیرهای متغیر وابسته به همراه تأخیرهای خطای پیش‌بینی است. این مدل میتواند به صورت ۳-۴ توضیح داده بشود.

$$\text{Output 'y'} = \text{constant} + \text{weighted sum of one or more past values of 'y'} \\ + \text{weighted sum of one or more past values of error 'e'}$$

شکل ۳-۴ میانگین متحرک خودهمبسته یکپارچه

تأخیرهای عبارت خطا را نمی‌توان به عنوان متغیر مستقل در نظر گرفت زیرا آنها توابع خطی ضرایب نیستند. از این رو، ضرایب مدل‌های میانگین متحرک خودهمبسته یکپارچه با خطاهای تأخیری باید با تکنیک‌های دیگری مانند بهینه‌سازی غیرخطی محاسبه شوند. اصطلاحات تأخیر سری‌های زمانی ثابت به عنوان «خودرگرسیون» نامیده می‌شوند، در حالی که تأخیرهای عبارات خطای پیش‌بینی شده به عنوان «میانگین متحرک» نامیده می‌شوند. سری زمانی که برای ثابت کردن آن نیاز به تفکیک دارد، نسخه «یکپارچه» یک سری ثابت است. این مدل‌ها به صورت  $ARIMA(p, d, q)$  نشان داده می‌شوند، جایی که  $p$  نشان‌دهنده ترتیب قسمت اتورگرسیون<sup>۲</sup>  $d$  درجه اولین تفاوت درگیر و  $q$  نشان‌دهنده ترتیب قسمت میانگین متحرک است.

بخش اتورگرسیون مدل با مرتبه  $p$  مانند معادله ۳-۲ نشان داده می‌شود.

$$Y_t = c + \Phi_1 Y_{t-1} + \Phi_2 Y_{t-2} + \dots + \Phi_p Y_{t-p} + e_t \quad (۳-۲)$$

همچنین مدل میانگین متحرک  $q$  به صورت معادله ۳-۳ تعریف میشود:

$$Y_t = c + \Theta_1 e_{t-1} + \Theta_2 e_{t-2} + \dots + \Theta_p e_{t-p} + e_t \quad (۳-۳)$$

جایی که  $Y$  خروجی یک سری زمانی مانند داده‌های مصرف برق و  $e_t$  سری خطا است. این مدل‌ها از یک روش رایج پیروی می‌کنند

ARIMA<sup>۱</sup>  
autoregressive<sup>۲</sup>

## ۴-۳ سری زمانی فازی

سری های زمانی فازی مشاهدات سری زمانی با مقادیر زبانی هستند تا مقادیر عددی معمولی یا واضح مشاهدات. بنابراین، قوانین مرسوم تحلیل سری های زمانی را نمی توان برای مطالعه این موارد به کار برد. سانگ<sup>۳</sup> و چیسوم<sup>۴</sup> [۲۳] این مفهوم را معرفی کردند و چندین تعریف رسمی برای سری های زمانی فازی ارائه کردند. مطالعات بعدی بر تقسیم بندی جهان گفتمان و به دنبال آن ایجاد روابط فازی متمرکز شد. سپس مقادیر پیش بینی شده و برای به دست آوردن خروجی عددی غیرفازی می شوند. لازم به ذکر است که انتخاب مناسب طول هر بازه فازی می تواند دقت پیش بینی را بسیار بهبود بخشد. برای مطالعات پیش‌بینی انرژی ساختمان، چالش در استخراج وزن‌های روابط منطق فازی، توابع عضویت و قوانین نهفته است.

## ۵-۳ استدلال مبتنی بر مورد<sup>۵</sup>

استدلال مبتنی بر مورد<sup>۵</sup> مبتنی بر یادآوری اطلاعات از یک پرونده قبلی برای حل یک پرونده جدید است. مخالف با ایده استخراج قواعد از مشاهدات که می تواند در یک مجموعه عمومی اعمال شود است. بلکه این فرآیند متکی بر موارد مشابهی است که در گذشته به آن پرداخته شده است و نه چندان متدولوژی حل آنها. منبع دانش اولیه در استدلال مبتنی بر مورد<sup>۵</sup> حافظه ای از موارد ذخیره شده است که قسمت های قبلی خاص را ضبط می کند [۲۴]. فرمول اولیه این مفهوم برگرفته از مطالعه نقش یادآوری در استدلال انسان است [۲۵]. استدلال مبتنی بر مورد در کاربرد خود در پیش‌بینی مصرف انرژی ساختمان، مواردی را در نظر می‌گیرد که دارای انواع مشابهی از متغیرهای ورودی هستند و سعی می‌کند بر اساس سناریوهای مشابه قبلی مدل‌سازی کند.

## ۶-۳ مدل‌های ترکیبی<sup>۶</sup>

مدل های ترکیبی ترکیبی از دو یا چند تکنیک یادگیری ماشینی هستند. این مدل‌ها قوی‌تر هستند، زیرا اغلب مزایای تکنیک‌های فردی درگیر را تحسین می‌کنند و دقت پیش‌بینی را بهبود می‌بخشند. متدهای بسیار متنوعی برای مدل‌های ترکیبی پیاده‌سازی و تست شده اند. از میان انبوهی از این مدل‌ها می‌توانیم به چند مورد زیر اشاره بکنیم:

- شبکه‌های عصبی مصنوعی و الگوریتم‌های تکاملی [۲۶]
- ماشین بردار پشتیبان و میانگین متحرک خودهمبسته یکپارچه [۲۷]

<sup>۳</sup>Song

<sup>۴</sup>Chissom

<sup>۵</sup>Case-based reasoning

<sup>۶</sup>Hybrid Models

- شبکه عصبی فازی در حال تکامل وزنی [۲۸]
- شبکه‌ی عصبی مصنوعی و میانگین متحرک خودهمبسته یکپارچه [۲۹]
- ...

لازم به ذکر است که توضیحات مربوط به مدل‌های ترکیبی و معادلات مربوط به هریک در بخش مربوط به کامل کردن متون ارائه خواهند شد.

### ۷-۳ خلاصه

با توجه به توضیحات داده شده ی بالا هر یک از این الگوریتم‌ها مزایا و معایب خودشان را در کار عملی پیش‌بینی داده‌های سری زمانی نشان خواهند داد. در مسیر پیش‌بینی داده‌های زمانی مصرف انرژی ساختمان‌ها از الگوریتم‌های مختلفی همچون ماشین بردار پشتیبان، شبکه‌های عصبی مصنوعی، میانگین متحرک خودهمبسته یکپارچه، سری زمانی فازی، استدلال مبتنی بر مورد و مدل‌های ترکیبی استفاده شده است. به طور کلی مدل‌های متنوع دیگری نیز در این مسئله وجود دارند که قادر به ارائه‌ی نتایج دقیق به متخصصین هستند. نکته‌ی بسیار مهم در این الگوریتم‌ها این است که اغلب آن‌ها به تنهایی و بدون داشتن مجموعه‌ی داده‌های آموزشی که کیفیت مناسبی را دارند کارایی چندان مناسبی نخواهند داشت. لازم به ذکر است که الگوریتم‌های هوش مصنوعی نیازمند منابع محاسباتی گسترده‌ای هستند که خود این امر یک محدودیت برای آن‌ها به حساب می‌آید. در صورتی که هریک از این موارد برای این الگوریتم‌ها رعایت نشوند یعنی داده‌های زیاد و با کیفیت و همچنین ارائه‌ی سیستم‌های قدرتمند برای انجام محاسبات به نتیجه‌ی مطلوب و دلخواه نخواهیم رسید.

## فصل چهارم

ارزیابی نتایج تجربی بر روی مجموعه‌های

داده

پس از معرفی الگوریتم‌های متنوع و شرح مسئله نوبت به بررسی و ارزیابی آن‌ها بر روی مجموعه‌های داده متنوع می‌شود. در این فصل ابتدا معیارهای ارزیابی معرفی شده‌اند و سپس نتایج الگوریتم‌های مختلف معرفی شده برای پیش‌بینی داده‌های سری‌های زمانی مصرف انرژی ساختمان‌ها معرفی و مورد بحث قرار گرفته‌اند. و در نهایت بهینه‌ترین روش‌ها در صورت ممکن معرفی شدند.

## ۱-۴ معیارهای ارزیابی

میانگین درصد مطلق خطا<sup>۱</sup>، همچنین به عنوان میانگین درصد انحراف مطلق<sup>۲</sup> شناخته می‌شود، معیاری برای دقت پیش‌بینی یک روش پیش‌بینی در آمار است. معمولاً دقت را به عنوان نسبتی که با فرمول ۱-۴ تعریف می‌شود بیان می‌کند:

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right| \quad (1-4)$$

که در آن  $A_t$  مقدار واقعی و  $F_t$  ارزش پیش‌بینی شده است. تفاوت آن‌ها بر ارزش واقعی  $A_t$  تقسیم می‌شود. مقدار مطلق در این نسبت برای هر نقطه پیش‌بینی شده در زمان جمع می‌شود و بر تعداد نقاط برازش  $n$  تقسیم می‌شود.

میانگین درصد مطلق خطا<sup>۱</sup> معمولاً به عنوان یک تابع ضرر<sup>۳</sup> برای مسائل رگرسیونی و در ارزیابی مدل استفاده می‌شود، زیرا تفسیر بسیار شهودی آن بر حسب خطای نسبی است. در قسمت‌های بعدی این بخش به روز خواهد شد و دو معیار دیگر نیز به آن اضافه خواهند شد.

## ۲-۴ نتیجه‌ی روش‌های مورد بررسی

در این بخش با توجه به دانش کسب شده از بخش‌های قبل مانند توضیحات انواع الگوریتم‌ها و نحوه‌ی کارکردن هر کدام و معرفی معیارهای ارزیابی‌مان الگوریتم‌های مختلف بر روی دیتاست‌های متنوع اجرا شده‌اند. در جدول زیر یک خلاصه از روش‌های معرفی شده آمده‌اند.

تکنیک‌های پیش‌بینی سری‌های زمانی فوق با موفقیت برای پیش‌بینی مصرف انرژی ساختمان استفاده شده‌اند. هر تکنیک دارای ویژگی‌های سودمند خاصی است که باید به طور مناسب در مورد مورد استفاده قرار گیرد. این بخش مزایا و معایب هر یک را برای تکنیک‌هایی که قبلاً مورد بحث قرار گرفت، روشن می‌کند.

<sup>۱</sup> mean absolute percentage error (MAPE)

<sup>۲</sup> mean absolute percentage deviation (MAPD)

<sup>۳</sup> Loss function

مدل	نوع دیتا	طول داده‌ی تمرین	میانگین درصد مطلق خطا <sup>۱</sup> (%)	زمان صرف شده	ارجاع
شبکه‌های عصبی مصنوعی	بار ساعتی برق	یک سال	۱.۶۹-۱.۸۱	۳۵ ثانیه	[۳۰]
ماشین بردار پشتیبان	داده های بار خنک کننده ساعتی و آب و هوا	یک ماه	۱.۰۰۱-۱.۰۱۶	کمتر از یک دقیقه	[۳۱]
سری فازی زمانی	بار برق روزانه	شش ماه	۱.۲۳-۱.۶۳	خارج از دسترس	[۳۲]
میانگین متحرک خودهمبسته یکپارچه	پیک تقاضای برق ماهانه	شش سال	۱.۰۵-۲.۵۹	خارج از دسترس	[۳۳]
روش‌های ترکیبی	شرح داده خواهند شد	-	-	-	-

جدول ۴-۱ نتیجه‌ی الگوریتم‌های هوش مصنوعی

### ۳-۴ مقایسه و بررسی روش‌های معرفی شده

شبکه‌های عصبی مصنوعی<sup>۴</sup> مزایای بیشتری نسبت به مدل‌های آماری دارد، زیرا می‌تواند نقشه‌برداری را انجام دهد رابطه ورودی و خروجی بدون ایجاد وابستگی پیچیده در میان ورودی‌ها مشاهده می‌شود که شبکه‌های عصبی مصنوعی<sup>۴</sup> عملکرد بسیار بهتری را در مقایسه با تکنیک‌های قبلی اجرا شده برای نقشه‌برداری غیر خطی ارائه می‌دهد. شبکه‌های عصبی مصنوعی<sup>۴</sup> می‌تواند مدل‌سازی غیرخطی را بدون هیچ گونه دانش قبلی در مورد روابط بین ورودی و خروجی انجام دهد متغیرها بنابراین، اینها مدل‌سازی عمومی‌تر و انعطاف‌پذیرتر هستند تکنیک برای پیش‌بینی با این حال، شبکه‌های عصبی مصنوعی<sup>۴</sup> وابسته به مقداردهی اولیه وزن است، حداقل‌های محلی و مشکل همگرایی کند را نشان می‌دهد. علاوه بر این، به دست آوردن تعادل بین بیش‌برازش و تعمیم برای شبکه‌های عصبی مصنوعی همیشه یک چالش است. از سوی دیگر، میانگین متحرک خودهمبسته یکپارچه<sup>۵</sup> یک تقریب جهانی است که به اندازه کافی عناصر رگرسیون و میانگین گرفته شده است به طوری که می‌توان تقریب را متناسب با هر سری زمانی انجام داد. با این حال، شناسایی میانگین متحرک خودهمبسته یکپارچه<sup>۵</sup> پیچیده و زمان‌بر است و بسیاری از مدل‌های میانگین متحرک خودهمبسته یکپارچه<sup>۵</sup> هیچ تفسیر ساختاری ندارند. شناسایی و تخمین می‌تواند به دلیل تأثیرات پرت به شدت تحریف شود. برای مشکلات پیش‌بینی انرژی ساختمان، ماشین بردار پشتیبان<sup>۶</sup> می‌تواند با مسائلی مانند نمونه کوچک، غیرخطی، ابعاد بالا و حداقل نقاط محلی مقابله کند. معمولاً داده‌های بلندمدت دارای ویژگی‌های نمونه‌های کوچک هستند و این امر ماشین بردار

<sup>۴</sup>Artificial Neural Network (ANN)

<sup>۵</sup>AutoRegressive Integrated Moving Average (ARIMA)

<sup>۶</sup>Support Vector Machine (SVM)

پشتیبان<sup>۶</sup> را برای پیش‌بینی داده‌های بلندمدت مناسب می‌کند. علاوه بر این، روش رگرسیون ماشین بردار پشتیبان<sup>۶</sup> نیز مانند شبکه‌های عصبی مصنوعی قابلیت مناسبی برای برازش و تعمیم دارد. یک نقطه قوت خاص استفاده از یک تابع هسته برای معرفی غیرخطی بودن و مقابله با داده‌های ساختار یافته دلخواه است. با این حال، درست مانند دو تکنیک دیگر ذکر شده در بالا، ماشین بردار پشتیبان<sup>۶</sup> فاقد شفافیت نتایج است و به راحتی قابل تفسیر نیست. معمولاً تابع هسته به پارامترهای خاصی بستگی دارد که برای دستیابی به نتایج خوب باید بهینه شوند.

در مورد تکنیک استدلال مبتنی بر مور<sup>۷</sup> مزیت اصلی این است که تقریباً برای هر دامنه‌ای قابل اعمال است. سیستم استدلال مبتنی بر مور<sup>۷</sup> سعی نمی‌کند قوانینی را بین پارامترهای مسئله پیدا کند، بلکه فقط سعی می‌کند مسائل مشابه را در داده‌ها بیابد و از راه حل‌های این مسائل به عنوان راه حلی برای مورد مورد مطالعه استفاده کند. مزیت دوم این است که رویکرد استدلال مبتنی بر مور<sup>۷</sup> به یادگیری و حل مسئله بسیار شبیه است فرآیندهای شناختی انسان استدلال مبتنی بر مور<sup>۷</sup> ارتباط بین رویدادهای مشابه در گذشته و آینده را تشخیص می‌دهد. با این حال، استدلال مبتنی بر مور<sup>۷</sup> به ندرت برای پیش‌بینی سری‌های زمانی استفاده می‌شود. دلیل این امر این است که استفاده از استدلال مبتنی بر مور<sup>۷</sup> برای پردازش سری‌های زمانی جنبه‌های جدیدی را معرفی می‌کند که توالی‌ها می‌توانند بسیار طولانی و با طول‌های مختلف باشند. علاوه بر این، حجم عظیم داده و وجود نویز در این داده‌ها مرتبط با محدودیت‌های زمان واقعی، سیستم استدلال مبتنی بر مور<sup>۷</sup> را غیرضروری می‌کند. در مقابل، تکنیک‌های پیش‌بینی فازی در حل عدم قطعیت‌ها در پیش‌بینی بار بسیار خوب هستند. با این حال، الگوهای زمانی توسط مناطق سفت و سخت تعریف می‌شوند که تنظیم آنها در هنگام وجود نویز در مجموعه داده دشوار است. اغلب از پیچیدگی محاسباتی بالایی برخوردار است و ثابت ندارد. برای تکنیک پیش‌بینی فازی، سری‌های زمانی باید به سری‌های ثابت و تناوبی تبدیل شوند تا الگوهایی در سری‌های زمانی استخراج شود.

مدل‌های ترکیبی برای مقابله با مشکلات دنیای واقعی که اغلب ماهیت پیچیده‌ای دارند، مناسب هستند. یک مدل یادگیری ماشینی ممکن است نتواند پیچیدگی‌های ایجاد انرژی و داده‌های عملیاتی را به تصویر بکشد. در چنین مواردی، استفاده از مدل هیبریدی می‌تواند سودمند باشد. روش‌های ترکیبی ابزارهای تحلیلی قوی برای دسته‌بزرگی از مسائل پیچیده هستند که متمایل به روش‌های کلاسیک سنتی نیستند. با ترکیب روش‌های مختلف، ساختارهای خودهمبستگی پیچیده در داده‌ها را می‌توان با دقت بیشتری مدل‌سازی کرد. علاوه بر این، مشکل انتخاب مدل را می‌توان با کمی تلاش بیشتر آسان کرد. برای مثال یکی از مهم‌ترین و پرکاربردترین مدل‌های سری زمانی مدل شبکه‌های عصبی مصنوعی-میانگین متحرک خودهمبسته یکپارچه است. این مدل به عنوان ترکیبی از میانگین متحرک خودهمبسته یکپارچه<sup>۵</sup> و شبکه‌های عصبی مصنوعی<sup>۴</sup> از قدرت منحصر به فرد شبکه‌های عصبی مصنوعی<sup>۴</sup> و میانگین متحرک خودهمبسته یکپارچه<sup>۵</sup> به ترتیب در مدل‌سازی غیرخطی و خطی بهره می‌برد. به نظر می‌رسد که مزایای چنین روش‌هایی در برخورد با سری‌های غیر ثابت قابل توجه باشد. مولفه غیر خطی غیر ثابت را می

Case-based Reasoning (CBR)<sup>۷</sup>Artificial Neural Network AutoRegressive Integrated Moving Average (ANNARIMA)<sup>۷</sup>

توان با استفاده از مدل شبکه‌های عصبی مصنوعی<sup>۴</sup> و مولفه خطی ثابت و باقیمانده را می‌توان با مدل میانگین متحرک خودهمبسته یکپارچه<sup>۵</sup> مدل کرد. به روشی مشابه، روش‌های دیگر را می‌توان برای بهبود دقت پیش‌بینی ترکیب کرد در پایان این بخش یک جدول بزرگ و جامع در مورد مقایسه‌ی الگوریتم‌های مختلف و مزایا و معایب هر کدام خواهد آمد.

## ۴-۴ خلاصه

در این فصل به ارزیابی و مقایسه‌ی الگوریتم‌های معرفی شده در فصل سوم کردیم. ابتدا معیار ارزیابی مناسبی برای مقایسه‌ی الگوریتم‌های پیش‌بینی داده‌های سری‌های زمانی به نام میانگین درصد مطلق خطا<sup>۱</sup> معرفی کردیم و در ادامه با استفاده از مراجع گزارشمان نتیجه‌ی اجرای هریک از الگوریتم‌های معرفی شده بر روی مجموعه‌ی داده‌های خود مراجع گزارش داده شدند. در بخش سوم این فصل به مقایسه‌ی مفصل الگوریتم‌های خود پرداختیم و سعی در مقایسه‌ی آن‌ها با همدیگر کردیم. نکته‌ی مهمی که در بررسی‌ها متوجه آن شدیم این است که ترکیب چندین مدل هوش مصنوعی و یادگیری ماشین نتیجه‌ی مطلوبتری را نسبت به یک مدل منفرد فراهم آورد.



## فصل پنجم

### نتیجه‌گیری و پیشنهادها

در بخش پایانی گزارش، جمع‌بندی و مروری بر سیر مطالب عنوان شده در گزارش خواهیم داشت. همچنین نتایج حاصل را بیان کرده و پیشنهادهایی برای ادامه کار در این موضوع ارائه می‌دهیم.

## ۱-۵ نتیجه‌گیری

این گزارش ۶ الگوریتم برای پیش‌بینی مصرف انرژی ساختمان‌ها را مورد بررسی قرار داد که برای این الگوریتم‌ها داده‌های مصرف آینده‌ی ساختمان‌ها و مصرف گذشته‌شان موجود بود. همچنین در این مقاله اهمیت برخی متغیرها مانند وضعیت دمای محیط و تعداد ساکنین ساختمان در هر زمان نیز مورد توجه قرار گرفتند و اهمیت آن‌ها در تصمیم‌گیری مشخص گردید. چندین مدل یادگیری ماشین موفق با استفاده از داده‌های انرژی ثبت‌شده گذشته برای پیش‌بینی کوتاه‌مدت، میان‌مدت و بلندمدت توسعه یافته‌اند. مشاهده می‌شود که هر یک از تکنیک‌های توصیف شده دارای مجموعه‌ای از مزایا و معایب است. اینها با توجه به تجزیه و تحلیل داده‌های انرژی ساختمان به تفصیل تجزیه و تحلیل و ارائه شده‌اند. تأکید ویژه بر مدل ترکیبی داده شده است، که ترکیبی از دو یا چند تکنیک یادگیری ماشینی است به نحوی که هر مدل قدرت دیگری را تحسین می‌کند. به عنوان مثال، یک مدل ترکیبی که میانگین متحرک خودهمبسته یکپارچه و الگوریتم‌های تکاملی را در نظر می‌گیرد، می‌تواند از مدل میانگین متحرک خودهمبسته یکپارچه برای تعیین تناوب و خطی بودن استفاده کند، در حالی که الگوریتم تکاملی می‌تواند به طور موثر باقیمانده‌ها را تعیین کند. ترکیبات مختلفی از مدل ترکیبی و تازگی آنها در ادبیات شناسایی شده و به طور سیستماتیک در این مقاله ارائه شده است. مشاهده می‌شود که ترکیب تکنیک‌های پیش‌بینی سری‌های زمانی مانند شبکه‌ی عصبی مصنوعی، میانگین متحرک خودهمبسته یکپارچه به خوبی با تکنیک‌های بهینه‌سازی ترکیب می‌شوند. چنین ترکیب‌هایی به طور گسترده در تحقیقات اختصاص یافته به بهینه‌سازی ساختمان مورد بررسی قرار گرفته‌اند. انتظار می‌رود روند رو به رشد در تحقیقات در بهره‌وری انرژی ساختمان در پرتو انگیزه پایداری جهانی ادامه یابد. این امر نظارت و پیش‌بینی داده‌های انرژی در زمان واقعی را در این زمینه مرتبط و حیاتی می‌کند. این مقاله خلاصه‌ای جامع از تکنیک‌های پیش‌بینی موجود همراه با ترکیبی از مدل ترکیبی ارائه می‌کند و راه را برای تحقیقات آینده در زمینه مصرف انرژی ساختمان هموار می‌کند.

حوزه بهینه‌سازی ساختمان بر اساس یک شبکه گسترده جمع‌آوری داده، نظارت، پیش‌بینی، بهینه‌سازی و کنترل است. تمام این زیرساخت‌ها همواره به کل هزینه عملیاتی ساختمان می‌افزایند. چالش در اینجا بررسی مزایای اضافه شده از نظر هزینه سرمایه‌گذاری و هزینه به دست آمده به دلیل صرفه‌جویی در انرژی ناشی از بهینه‌سازی ساختمان است. مطالعات کمی وجود دارد که بخش مالی را برای کنترل عملکرد و بهینه‌سازی ساختمان برجسته می‌کند. این محدودیت در به اشتراک گذاری داده‌های هزینه یا به دلیل نیروهای بازار درگیر است یا به دلیل محرمانه بودن ماهیت داده‌های درگیر. لبی‌الدان<sup>۱</sup> و همکاران. کاربردهای شبکه حسگرها و محرک‌های بی‌سیم کم‌هزینه را برای مدل‌سازی اشغال و

<sup>۱</sup>Labeodan

کنترل روشنایی در یک ساختمان اداری مورد بحث قرار داد [۳۴]. هزینه کل سیستم تقریباً ۲۵۷۵ یورو برای ۱۲ ایستگاه کاری بود که شامل حسگرهای حرکتی بی سیم و سنسورهای صندلی بود. نتایج نشان می‌دهد که به طور متوسط ۲۴٪ کاهش در مصرف انرژی روشنایی برای یک دوره دو هفته‌ای با هزینه اجرا شده در حدود ۲۱۵ یورو برای هر ایستگاه کاری است. نویسندگان خاطرنشان کردند که هزینه اولیه بالاتر و عدم آگاهی از عوامل مؤثر در کاهش سرعت استقرار حسگرها هستند. با این حال، صرفه جویی در انرژی به دست آمده، سهولت استقرار و بهبود سنجش محیطی این را به عنوان یک راه حل مناسب برای دستیابی به عملکرد بهبود یافته ساختمان نشان می‌دهد. کومار و همکاران همچنین متوجه شد که هزینه سنسورهای نظارت کنترل کیفیت هوای داخلی الزامات استقرار در مقیاس بزرگ برای کنترل و اتوماسیون را برآورده نمی‌کند [۳۵]. لیلیس و همکاران اشاره کنید که علاقه به راه‌حل‌های مبتنی بر اینترنت اشیا<sup>۲</sup> مدرن برای بهینه‌سازی ساختمان به دلیل عدم برآورد منافع هزینه، مهار شده است [۳۶]. چن و همکاران اشاره کرد که هزینه مربوط به مصرف انرژی مجموعه تصادفی ساختمان‌ها در چین با سیستم‌های اتوماسیون ساختمان تقریباً دو برابر ساختمان‌های بدون سیستم اتوماسیون ساختمان است [۳۷]. این به دلیل نقص سنسور و نقص استراتژی کنترل است که منجر به افزایش قابل توجهی در مصرف انرژی نهایی می‌شود.

چند مطالعه مروری شبکه حسگر بی سیم را پوشش داده است که سیستم مدیریت انرژی ساختمان را برای کاربردهای خانه/ساختمان هوشمند فعال کرده است [۳۸، ۳۹]. از آنجایی که فناوری کنترل پیش‌بینی مدل هنوز در مرحله توسعه است و نیاز به بهینه‌سازی سنگین بر اساس نوع و عملکرد ساختمان دارد، پیاده‌سازی در حال حاضر بیشتر بر روی بستر آزمایشی و اعتبارسنجی تمرکز دارد. در عین حال، این فناوری هنوز با هزینه لازم برای استقرار در مقیاس‌های بزرگ در دسترس نیست. این چالش‌ها منجر به نفوذ آهسته اتوماسیون ساختمان و بهینه‌سازی در کل می‌شود. دامنه این مقاله مروری، با این حال، محدود به مطالعه تکنیک‌های پیش‌بینی سری‌های زمانی برای مصرف انرژی ساختمان است که بخشی جدایی‌ناپذیر از فرآیند بهینه‌سازی و کنترل ساختمان است.

## ۲-۵ پیشنهادها

به طور کلی الگوریتم‌های هوش مصنوعی که در زمینه‌ی پیش‌بینی سری داده‌های زمانی کار میکنند و بخش عمده‌ی آن‌ها که الگوریتم‌های یادگیری ماشین می‌شوند مشکلات و سختی‌های مخصوصی دارند از جمله محدودیت‌های مربوط به یادگیری آن‌ها که نیازمند داده‌های بسیرتر زیاد برای یادگیری و آموزش میباشد و همچنین نیاز به توان پردازشی بالای آن‌ها که از جمله مشکلات روش‌های هوش مصنوعی به طور کلی میباشد. برای حل این مشکل پیشنهاد میشود که الگوریتم‌های نوینی با استفاده از روش‌های ترکیبی توسعه داده بشوند که نیاز به داده‌های زیاد برای یادگیری در آن‌ها کمتر باشد و بتوانند با شبیه‌سازی آموزش ببینند و همچنین برای حل مشکل پردازش‌های سنگین با تحقیقات جدید به سمت

<sup>۲</sup>Internet Of Things (IoT)

برخط کردن یادگیری الگوریتم‌های هوش مصنوعی حرکت بکنیم به این صورت که تمام پردازش‌های مورد نیاز الگوریتم‌مان بر روی سرورهای قدرتمندی در سطح منطقه انجام بشوند و ساختمان‌ها مشکل پردازشی‌شان از این نظر مرتفع بشود و تنها برای انجام اندازه‌ی مشخصی از پردازش بر روی شبکه‌ی قدرتمندمان هزینه پرداخت کنند تا هزینه‌هایشان کاهش پیدا بکند.

## منابع و مراجع

- [1] Deb, Chirag, Zhang, Fan, Yang, Junjing, Lee, Siew Eang, and Shah, Kwok Wei. A review on time series forecasting techniques for building energy consumption. *Renewable and Sustainable Energy Reviews*, 74:902–924, 2017.
- [2] Al-Homoud, Mohammad Saad. Computer-aided building energy analysis techniques. *Building and Environment*, 36(4):421–433, 2001.
- [3] Crawley, Drury B., Hand, Jon W., Kummert, Michaël, and Griffith, Brent T. Contrasting the capabilities of building energy performance simulation programs. *Building and Environment*, 43(4):661–673, 2008. Part Special: Building Performance Simulation.
- [4] Pfafferott, Jens, Herkel, Sebastian, and Wapler, Jeannette. Thermal building behaviour in summer: long-term data evaluation using simplified models. *Energy and Buildings*, 37(8):844–852, 2005.
- [5] Bauer, M and Scartezzini, J-L. A simplified correlation method accounting for heating and cooling loads in energy-efficient buildings. *Energy and Buildings*, 27(2):147–154, 1998.
- [6] Dhar, A, Reddy, TA, and Claridge, DE. Modeling hourly energy use in commercial buildings with fourier series functional forms. 1998.
- [7] Dhar, A, Reddy, TA, and Claridge, DE. A fourier series model to predict hourly heating

- and cooling energy use in commercial buildings with outdoor temperature as the only weather variable. 1999.
- [8] Lei, Fei and Hu, Pingfang. A baseline model for office building energy consumption in hot summer and cold winter region. in *2009 International Conference on Management and Service Science*, pp. 1–4. IEEE, 2009.
- [9] Ma, Yuan, Yu, Jun-qi, Yang, Chuang-ye, and Wang, Lei. Study on power energy consumption model for large-scale public building. in *2010 2nd International Workshop on Intelligent Systems and Applications*, pp. 1–4. IEEE, 2010.
- [10] Cho, Sung-Hwan, Kim, Won-Tae, Tae, Choon-Soeb, and Zaheeruddin, M. Effect of length of measurement period on accuracy of predicted annual heating energy consumption of buildings. *Energy conversion and management*, 45(18-19):2867–2878, 2004.
- [11] Lam, Joseph C, Wan, Kevin KW, Wong, SL, and Lam, Tony NT. Principal component analysis and long-term building energy simulation correlation. *Energy Conversion and Management*, 51(1):135–139, 2010.
- [12] Clarke, Joe A and Clarke, Joseph Andrew. *Energy Simulation in Building Design*. Routledge, 2001.
- [13] McQuiston, Faye C, Parker, Jerald D, and Spitler, Jeffrey D. *Heating, ventilating, and air conditioning: analysis and design*. John Wiley & Sons, 2004.
- [14] Al-Homoud, Mohammad Saad. Computer-aided building energy analysis techniques. *Building and Environment*, 36(4):421–433, 2001.
- [15] Kalogirou, Soteris A, Neocleous, CC, and Schizas, CN. Building heating load estimation using artificial neural networks. in *Proceedings of the 17th international con-*

- ference on Parallel architectures and compilation techniques*, vol. 8, p. 14. Citeseer, 1997.
- [16] Kalogirou, Soteris A. Artificial neural networks in energy applications in buildings. *International Journal of Low-Carbon Technologies*, 1(3):201–216, 2006.
- [17] Olofsson, Thomas, Andersson, Staffan, and Östin, Ronny. A method for predicting the annual building heating demand based on limited performance data. *Energy and Buildings*, 28(1):101–108, 1998.
- [18] Olofsson, Thomas and Andersson, Staffan. Long-term energy demand predictions based on short-term measured data. *Energy and Buildings*, 33(2):85–91, 2001.
- [19] Dong, Bing, Cao, Cheng, and Lee, Siew Eang. Applying support vector machines to predict building energy consumption in tropical region. *Energy and Buildings*, 37(5):545–553, 2005.
- [20] Lai, Florence, Magoules, Frederic, and Lherminier, Fred. Vapnik’s learning theory applied to energy consumption forecasts in residential buildings. *International Journal of Computer Mathematics*, 85(10):1563–1588, 2008.
- [21] Liang, Jian and Du, Ruxu. Model-based fault detection and diagnosis of hvac systems using support vector machine method. *International Journal of refrigeration*, 30(6):1104–1114, 2007.
- [22] Li, Qiong, Ren, Peng, and Meng, Qinglin. Prediction model of annual energy consumption of residential buildings. in *2010 international conference on advances in energy engineering*, pp. 223–226. IEEE, 2010.
- [23] Song, Qiang and Chissom, Brad S. Fuzzy time series and its models. *Fuzzy sets and systems*, 54(3):269–277, 1993.

- [24] Leake, David B. Cbr in context: The present and future. *Case-based reasoning: Experiences, lessons, and future directions*, pp. 3–30, 1996.
- [25] Schank, Roger C. *Dynamic memory: A theory of reminding and learning in computers and people*. cambridge university press, 1983.
- [26] Azadeh, Ali, Ghaderi, Seyed F, Tarverdian, S, and Saberi, Morteza. Integration of artificial neural networks and genetic algorithm to predict electrical energy consumption. *Applied mathematics and computation*, 186(2):1731–1741, 2007.
- [27] Nie, Hongzhan, Liu, Guohui, Liu, Xiaoman, and Wang, Yong. Hybrid of arima and svms for short-term load forecasting. *Energy Procedia*, 16:1455–1460, 2012.
- [28] Chang, Pei-Chann, Fan, Chin-Yuan, and Lin, Jyun-Jie. Monthly electricity demand forecasting based on a weighted evolving fuzzy neural network approach. *International Journal of Electrical Power & Energy Systems*, 33(1):17–27, 2011.
- [29] Wang, Jujie, Wang, Jianzhou, Li, Yaning, Zhu, Suling, and Zhao, Jing. Techniques of applying wavelet de-noising into a combined model for short-term load forecasting. *International Journal of Electrical Power & Energy Systems*, 62:816–824, 2014.
- [30] Chitsaz, Hamed, Shaker, Hamid, Zareipour, Hamidreza, Wood, David, and Amjady, Nima. Short-term electricity load forecasting of buildings in microgrids. *Energy and Buildings*, 99:50–60, 2015.
- [31] Li, Qiong, Meng, Qinglin, Cai, Jiejing, Yoshino, Hiroshi, and Mochida, Akashi. Applying support vector machine to predict hourly cooling load in the building. *Applied Energy*, 86(10):2249–2256, 2009.
- [32] Efendi, Riswan, Ismail, Zuhaimy, and Deris, Mustafa Mat. A new linguistic out-sample approach of fuzzy time series for daily forecasting of malaysian electricity load demand. *Applied Soft Computing*, 28:422–430, 2015.



- [33] Rallapalli, Srinivasa Rao and Ghosh, Sajal. Forecasting monthly peak demand of electricity in india—a critique. *Energy policy*, 45:516–520, 2012.
- [34] Labeodan, Timilehin, De Bakker, Christel, Rosemann, Alexander, and Zeiler, Wim. On the application of wireless sensors and actuators network in existing buildings for occupancy detection and occupancy-driven lighting control. *Energy and Buildings*, 127:75–83, 2016.
- [35] Kumar, Prashant, Skouloudis, Andreas N, Bell, Margaret, Viana, Mar, Carotta, M Cristina, Biskos, George, and Morawska, Lidia. Real-time sensors for indoor air monitoring and challenges ahead in deploying them to urban buildings. *Science of the Total Environment*, 560:150–159, 2016.
- [36] Lilis, Georgios, Conus, Gilbert, Asadi, Nastaran, and Kayal, Maher. Towards the next generation of intelligent building: An assessment study of current automation and future iot based systems with a proposal for transitional design. *Sustainable cities and society*, 28:473–481, 2017.
- [37] Chen, Zheliang, Wang, Fulin, and Feng, Qingqing. Cost-benefit evaluation for building intelligent systems with special consideration on intangible benefits and energy consumption. *Energy and Buildings*, 128:484–490, 2016.
- [38] Kazmi, Aqeel H, O’grady, Michael J, Delaney, Declan T, Ruzzelli, Antonio G, and O’hare, Gregory MP. A review of wireless-sensor-network-enabled building energy management systems. *ACM Transactions on Sensor Networks (TOSN)*, 10(4):1–43, 2014.
- [39] Kuzlu, M, Pipattanasomporn, M, and Rahman, S. Review of communication technologies for smart homes/building applications. in *2015 IEEE Innovative Smart Grid Technologies-Asia (ISGT ASIA)*, pp. 1–6. IEEE, 2015.